

Universidad de Buenos Aires

Maestría en Explotación de Datos
y Descubrimiento del Conocimiento

Data Mining en Economía y Finanzas

Libro de la Asignatura

Edición 2026

Did you ask a good question today?

última actualización 2026-09-22 03:54

Tabla de Contenidos

1La Asignatura....6
1.1Sobre este documento....6
1.2Links fundamentales año 2026....7
1.3Cronograma de la Asignatura año 2026....8
1.4Dedicación Estimada....9
1.5UBA Modalidad y Criterios de Aprobación y Evaluación....10
1.5.1Modalidad y Criterios de Aprobación y Evaluación Competencias....11
1.5.2Experimentos Colaborativos....12
1.5.3Evaluación participación en foro/chat Zulip....13
1.5.4Evaluación video presentaciones....14
1.5.5Evaluación Individual....16
1.6Misión de la Asignatura....17
1.6.1Objetivos de la Asignatura....17
1.7 Unidades Temáticas....18
1.7.1Tecnologías a enseñar y reforzar....19
1.8Bibliografía General de la Asignatura....20
2Metodología de Enseñanza....22
2.1Generalidades....22
2.2Manifiesto Pedagógico....22
2.3Pensamiento Creativo – Tinkering....23
2.4Dinámica Constructivista en el Aula....24
2.5Authentic Learning....24
2.6Flipped Classroom Forte....24
2.7Conectivismo....25
2.8Active Learning....25
2.9Evaluación Continua....26
3Abróchense los cinturones....28
3.1Alta en Plataformas....28
3.1.1Zulip herramienta de chat y foros discusión....28
3.1.2Comisión Jueves : Google Sheet Colaborativa de la Asignatura....29
3.1.3Plataforma Hypothes.is....29
3.1.4Plataforma ChatGPT/Claude....29
3.1.5Plataforma GitHub....30
3.1.6Check In a la Asignatura en Zulip....31
4Herramientas, Conceptos, Operación y Buenas pácticas....34
4.1UBA Preguntas de código, Google Cloud, Git, etc en clases presenciales....34
4.2UBA Preguntas de código, Google Cloud, Git, etc en Sesiones de Tutorias....34
4.3Zulip....34
4.3.1Buenas prácticas para el uso de Zulip....36
4.3.2Participaciones extraordinariamente significativas en Zulip....37
4.3.3Participaciones significativas en Zulip....37
4.3.4Mensajes Privados a los profesores Permitidos....37
5Tutorías....39
5.1Objetivo....39
5.2Tuplas de tutoría....39
5.3Agenda de sesiones de tutorías....39
5.4Trabajo previo....39
5.5Sesión de tutoría....40
6Git y GitHub....41

6.1.1conceptos y operación....41
6.2Librería data.table del lenguaje R....42
7Niveles de complejidad....44
7.1Etapa Preprocesamiento de Datos....44
7.1.1Armado del Target....44
7.1.2Dimensionalidad del dataset....44
7.1.3Tratamiento Valores faltantes....44
7.1.4Calidad de Datos....44
7.1.5Data Drifting....44
7.1.6Feature Engineering intra mes....44
7.1.7Feature Engineering histórico....44
7.1.8Aceleración Procesamiento....44
7.2Etapa Modelado....45
7.2.1Clase Target....45
7.2.2Estrategia Entrenamiento....45
7.2.3Algoritmo....45
7.2.4Optimizacion de Hiperparámetros....45
7.3Etapa Puesta en Produccion....45
8Experimentos Colaborativos....45
8.1Documento Colaborativo Google Slides....47
8.2Problemas disponibles y alumnos avanzados....48
8.3Configuración de los grupos....48
8.4Forma de pre registración....48
8.5Negociación de Problemas : vacancia....48
8.6Negociación de Problemas : sobreoferta....49
8.7Asignación Grupo A vs Grupo B....49
8.8Antagonismo de los grupos....49
8.9Perídos de análisis de los grupos....50
8.10Aprobación de Diseños Experimentales....51
8.11Ceteris Paribus....52
8.12Capítulo Conclusiones....52
8.13Video Presentaciones Ejecutivas....52
9¿Cómo seguir?....53
9.1Mantenerse actualizado....53
9.2Datasets Públicos....53
10Empiricismo en la Ciencia de Datos....54
10.1.1Bibliografía Introductoria....54
11Las dos culturas en el modelado predictivo....55
12Estimando la Ganancia de un modelo predictivo....56
12.1Bibliografía Introductoria....56
12.2Sesgo Varianza en la estadística clásica....56
12.2.1Bibliografía Inicial....56
12.3Sesgo Varianza en el moderno Machine Learning....57
12.3.1Bibliografía Inicial....57
13Análisis exploratorio de datos....58
13.1Consistencia longitudinal de los atributos....58
13.2Drifting de atributos....58
13.3Tratamiento de variables "rotas"....58
13.4Tratamiento de nulos....58
13.5Tratamiento de outliers....58
14Algoritmo: Árbol de Decisión....59
14.1Bibliografía Inicial....59

14.2El hiperparámetro cp en la librería rpart....59
15Comparación de Modelos Predictivos....60
15.1Bibliografía Inicial....60
16Optimización de Hiperparámetros....61
16.1Bibliografía Introductoria....61
16.2Grid Search....61
16.3Bayesian Optimization....61
17MLOPS....62
17.1Bibliografía Inicial....62
18Curva ROC....63
18.1Bibliografía....63
18.2Curva ROC de un split en un árbol de decisión....63
18.3Curva ROC de un modelo predictivo....63
18.4Relación de la Curva ROC con la función de ganancia....63
19Controlando el False Discovery Rate....64
19.1Bibliografía Introductoria....64
20Feature Engineering....65
20.1Bibliografía Introductoria....65
20.2Cambiando la clase....65
20.3Variables Manuales....65
20.4Transformaciones tradicionales....65
20.5Variables históricas....66
20.6Lags y delta lags....66
20.7Tendencias....66
20.8Medias móviles....66
20.9Ajuste por Inflación....66
20.10Variables hojas de un Random Forest....66
20.11Reducción de la dimensionalidad para acelerar....66
21Ensembles de Modelos....67
21.1Bibliografía Introductoria....67
22Algoritmo: Random Forest....68
22.1Bibliografía Introductoria....68
23Algoritmo: Gradient Boosting of Decision Trees....69
23.1Bibliografía Introductoria....69
23.2XGBoost....69
23.2.1Bibliografía XGBoost....69
23.3Optimización hiperparámetros XGBoost....69
23.4Bibliografía LightGBM....69
23.5Optimización hiperparámetros LightGBM....69
24Estrategia de Entrenamiento....70
24.1Determinación de los mejores períodos para entrenar....70
24.2Acelerando el entrenamiento : evitando el cross validation....70
24.3Acelerando el entrenamiento : Undersampling de la clase mayoritaria....70
25Importancia de Variables....71
25.1Bibliografía Introductoria....71
25.2Valores Shapley....71
26Ensembles de Modelos Segunda Parte....72
26.1Semilleríos....72
26.2Hibridación de Semilleríos....72
27Acelerando el procesamiento....73
27.1Bibliografía Inicial....73
27.2El problema de la calibración en Gradient Boosting....73

27.3Otra forma de cortar....73
28Clustering jerárquico basado en la distancia de Random Forest....74
29Storytelling....75
29.1Historia....75
29.2Bibliografía Introductoria Storytelling....77
29.3Herramientas para grabar videos....77
29.4Grabación sencilla de videos con Microsoft Teams....78
29.5Torneo de Videos....78
30Artículos de negocios....79
31El Recuperatorio....79
32Hoja de Ruta clases jueves en construcción....80
32.1Introducción y construcción Primera Competencia....80
32.2Construcción Ultima Competencia....82

1 La Asignatura

Esta asignatura en su versión 2026 será una **intensa** y **personalizada** experiencia emocional, social y cognitiva, con una dinámica totalmente distinta a las que está acostumbrado; le demandará un gran involucramiento. Los instructores intentarán sorprenderlo en cada tutoría y clase.

Aprenderá a resolver un problema real, con datos reales (millones de registros y cientos de columnas), procesará en la nube Google Cloud y utilizará los algoritmos estado del arte como ser la Bayesian Optimization y LightGBM. Será motivado a pensar *out of the box* en Feature Engineering, organizando el trabajo bajo la metodología de MLOps.

La materia posee competencias de ciencias de datos con el objetivo de construir el mejor modelo predictivo que resuelva el problema de retención de clientes financieros.

La metodología es la de flipped classroom, deberá venir con los experimentos corridos a las clases , mantendrá contacto asincrónico con los profesores y compañeros con la herramienta de foro/chat Zulip y periódicamente deberá asistir a tutorías virtuales para recibir retroalimentación sobre el avance de su modelado. En las clases presenciales se desarrollarán dinámicas de *active learning* en contraposición a la tradicional dinámica de clases magistrales.

El centro de esta asignatura es usted formando con sus pares una comunidad de aprendizaje colaborativo, recibiendo retroalimentación personalizada en tutorías.

1.1 Sobre este documento

No se sienta abrumado por la extensión y detalle de este documento, en la primera clase se le explicará coloquialmente que se espera de usted.

No imprima en papel este documento; está solo completo tan solo hasta el capítulo 3, qué es lo que necesita para iniciar la materia. Se le irá agregando contenido los próximos días a los primeros capítulos, y el resto a medida que avance la materia.

1.2 Links fundamentales año 2026

UBA DMEyF 2026 Links Fundamentales	
Zulip	https://uba26.zulip.rebelare.com/
repositorio GitHub oficial	https://github.com/dmecoyfin/dmeyf2026
Diccionario de Datos	https://storage.cloud.google.com/open-courses/dmeyf2026-9c6f/DiccionarioDatos_2026.ods
Dataset Primera Competencia	https://storage.googleapis.com/open-courses/dmeyf2026-9c6f/competencia_01_crudo.csv
Google Sheet Colaborativa Comisión Jueves	https://docs.google.com/spreadsheets/d/1Q03J0AfgDxS2wo79ZUlon8Q32_jfAhyx-f1e0r6sXws/edit?usp=sharing
Google Slides de Experimentos Colaborativos	Aún no definido
Dataset Ultima Competencia	Aún no definido

1.3 Cronograma de la Asignatura año 2026

Eventos Importantes ambas comisiones **DMEyF 2026**			
Fecha	**Hora**	**Canal**	**Actividad**
Mie 05-ago	20:00	email	Envio por email de este documento a alumnos
Lun 10-ago	19:00 a 22:00	Presencial	Clase 01 comision Lunes
Jue 13-ago	19:00 a 22:00	Presencial	Clase 01 comision Jueves
Mar 18-ago	19:00 a 22:00	Presencial	Comisión lunes, clase movida por feriado
Mar22-sep	random	Zulip	Disponibilizacion Instructivo instalacion ambiente Google Cloud
sem 22-sep	semana	Presencial	Lanzamiento Experimentos Colaborativos
sem 28-sep	semana	Virtual	Lanzamiento Tutorias, primer encuentro
Dom 04-oct	'23:59	Zulip	Entrega video Miranda Wintour
Dom 11-oct	11:59:00 PM	Zulip	Cierre **Primera Competencia**
sem 12-oct	semana	Virtual	Tutorias *Disaster Autopsy*
Mar 13-oct	19:00 a 22:00	Presencial	Comisión lunes, clase movida por feriado
Jue 05-nov	19:00 a 22:00	Presencial	Clase Plenaria (AMBAS comisiones)
Mar 23-nov	19:00 a 22:00	Presencial	Comisión lunes, clase movida por feriado
Mie 09-dic	23:59	Zulip	Cierre **Última Competencia**
Jue 10-dic	19:00 a 21:59	Presencial	Examen Individual
Dom 13-dic	23:59	Zullip	Fecha límite entrega del video a Michelina Porto
Lun 14-dic	11:00	Zulip	Lanzamiento Torneo de Videos
Sab 19-dic	23:30	Zulip	Fin Torneo de Videos
Dom 20-dic	23:30	Zulip	Publicación de Notas en la cartelera de Zulip
Lun 21-dic	23:30	email	Emails con recuperatorios

1.4 Dedicación Estimada

La materia en el año 2026 consta de 54 horas de encuentros presenciales.
Además de las horas presenciales hacen falta, en promedio, otras 54 horas entre asistencia a las tutorias virtuales y trabajo asincrónico. Resumiendo, usted deberá dedicar en promedio 54 + 54 = 108 horas a esta materia

La asistencia a las tutorías virtuales es obligatoria.

Se estima que el alumno en promedio deberá dedicarle otras 54 horas fuera de las clases presenciales a :

- diseñar, ejecutar, interpretar los resultados de experimentos que intenten mejorar los modelos predictivos. En función de esa interpretación, idear nuevos experimentos superadores
- avanzar etapas del proyecto para mostrar en la sesión de tutoria
- asistir a la sesiones tutorías virtuales, de 55 minutos cada una.
- instalar, aprender a manejar herramientas como Git, GitHub, Google Cloud
- ver videos/lecturas previas para estar preparado para la siguiente clase sincrónica, comentado en Zulip lo leído.
- responder quizzes asincrónicos en Zulip
- Zulip
    - leer los mensajes de los profesores y compañeros
    - preguntar a los profesores
    - responder a sus compañeros
- programar scripts, realizar modificaciones a los scripts oficiales de la materia
- operar el entorno Google Cloud, administrando efectivamente las restricciones
- participar de "Experimentos Colaborativos”

Todas las horas anteriores no contemplan temas que los alumnos quieren profundizar por su cuenta. Contemplar pasivamente la pantalla a la espera que una virtual machine de Google Cloud termine de procesar no cuenta para el cómputo de horas humanas dedicadas.

Históricamente hay un puñado de alumnos outliers que llegan con un ímpetu extraordinario a la maestría, la asignatura les resulta de interés para su futuro laboral, *disponen del tiempo*, que dedican la descomunal cantidad de 150 horas humanas asincrónicas a la asignatura.

1.5 UBA Modalidad y Criterios de Aprobación y Evaluación

La nota mínima de aprobación de la materia es 5.50 , la nota final oficial se redondea a un número entero, la máxima nota final posible es 10.

Nota Ordinaria	
Contribución Nota	Actividades Obligatorias
10%	Primera Competencia. Tarea grupal de 1 o 2 personas
40%	Última Competencia. Tarea grupal 1 o 2 personas
20%	Experimentos Colaborativos. Tarea Grupal
8%	Participación *significativa* en conversaciones el foro de la materia con herramienta *Zulip* .Tarea Individual
9%	Video Presentación de 5 minutos con storytelling a la Directora Comercial explicando perfiles de clientes que se dan de baja y proponiendo acciones de retención. Tarea Individual.
10%	Video Presentación de 5 minutos sobre lo más relevante de la confección del modelo de la Tercera Competencia, con storytelling dirigido la Gerenta de Business Intelligence. Tarea Individual
1%	Tutorias virtuales, asistir con grado de avance en el proyecto y participar del intercambio de ideas. Asistencia mandatoria.
1%	Evaluación individual comprobación de autoría de la Segunda Competencia
1%	Torneo de Videos, ser jurado en "duelos" de videos para calificar videos de pares. Tarea Individual
100%	Total

Todas las actividades anteriores son obligatorias. La no participación/entrega en cualquiera de ellas implica el desaprobar la materia.

La detección de no autoría de la segunda competencia implica desaprobar la materia.

1.5.1 Modalidad y Criterios de Aprobación y Evaluación Competencias

En las competencias se puede participar formando grupo de una sola persona, o grupos de dos personas; no están permitidos los grupos de tres o más personas. Puede formar grupos distintos en cada competencia, trabajar en algunas solo y en otras en grupo, etc

Cada competencia tendrá limitaciones sobre los algoritmos y datos que se pueden utilizar, usted deberá observar un cumplimiento estricto de dichas normas.

Es parte de la filosofía de la materia la reproducibilidad de los experimentos. Su repositorio personal GitHub de la materia deberá permanecer completamente público y abierto, accesible para los profesores y sus compañeros, durante todo el transcurso de la asignatura hasta cinco meses después de la entrega de las notas finales (servirá como material de referencia para quienes deban realizar un recuperatorio).

Usted deberá subir a su repositorio personal de la materia en GitHub los scripts y experimentos que partiendo del dataset original permitan a los profesores replicar exactamente sus entregas finales en las competencias , esto incluye a las semillas aleatorias.

Su solución definitiva será analizada por los profesores para:

- verificar que su entrega final fue generada por su script/notebook
- verificar que los scripts/notebooks cumplen con las condiciones de la competencia
- garantizar que está haciendo aportes significativos a la soluciones de la cátedra y a los "Experimentos Colaborativos"
- garantizar que la solución de su equipo es original y sustancialmente distinta a la de los otras personas de la cohorte.

Es una práctica común la existencia de meta grupos, desde el mismo inicio prevea que para lograr entregas significativamente distintas deberá en algún momento cortar esa simbiosis.

Una vez cumplido exitosamente el requisito de originalidad, se pasa a evaluar la ganancia en los datos del mes del futuro.

Para cada competencia existirá una ganancia llamada “Línea de Muerte” que usted deberá superar para obtener un 5. Las ganancias por encima de la Línea de Muerte se normalizan y mapean al intervalo [5,10] de notas.

1.5.2 Experimentos Colaborativos

Ver el capítulo homónimo para entender en que consisten los experimentos colaborativos.

Rúbrica de Experimentos Colaborativos	
Porcentaje	**Concepto a Evaluar**
10%	Hipótesis Experimental, será brindada por los profesores Los alumnos buscarán bibliografía que soporta, o no, la hipótesis experimental.
30%	Diseño experimental y materiales. El diseño del experimento muestra una acabada comprensión del problema a resolver, los experimentos están precisamente especificados y detallados, los scripts son adecuados.
20%	Procedimientos y recopilación de resultados La ejecución de los experimentos es correcta, los parámetros iniciales y resultados capturados son los adecuados.
20%	Análisis de los resultados. Se interpretan correctamente los resultados obtenidos
20%	Resultados, conclusiones y discusión con pares La conclusión determina claramente si la hipótesis experimental se cumple o no. Se presentan los resultados en forma clara y convincente, se debaten los mismos con el resto de los alumnos. Se relacionan los resultados con la bibliografía original. Se proponen nuevos experimentos en caso de cuestionamientos externos.

Cada alumno participa en forma individual, los profesores le asignan a cada alumno problemas/tareas específicas.

1.5.3 Evaluación participación en foro/chat Zulip

Zulip es el sistema nervioso de la asignatura.
Pasan más cosas en Zulip que en las clases sincrónicas.

Ver el capítulo Zulip dentro de Herramientas, Conceptos y Operación el detalle de lo que se espera de usted en Zulip

Rúbrica de participación en foro Zulip	
Porcentaje	**Concepto a Evaluar**
30%	Contenido. Propone ideas profundas, signfiicativas, claras, fáciles de implementar y con potencial para el proyecto de la asignatura. Compartiendo resultados logra atraer la atención y colaboración de sus compañeros a sus posts. Idealmente se transforma en un líder conceptual del grupo.
30%	Contribución al dinamismo de la comunidad. Plantea preguntas interesantes y relevantes, intenta motivar las discusiones grupales sobre tópicos relevantes a la asignatura, debate positivamente, participa de conversaciones iniciadas por otros.
20%	Colaboración en dudas operativas, colabora rápida y acertadamente con compañeros que requieren algún tipo de asistencia operativa en alguna de las herramientas del curso, lenguaje de programación, etc Idealmente se transforma en un referente en un tema específico del grupo.
20%	Frecuencia. Todas las semanas participa con al menos **tres** posteos **relevantes**.

Cada alumno participa con su usuario en forma individual en Zulip

1.5.4 Evaluación video presentaciones

Debe leer la historia que genera la necesidad de las video presentaciones en el capítulo **Storytelling**.

Las video presentaciones deben cumplir mandatoriamente con las siguientes condiciones, en caso contrario se le asignará una nota de cero y no participará del Torneo de Videos:

- La duración esperada es de alrededor de 5:00 minutos; jamás podrá exceder los 5:30 minutos.
- su cara, mostrando claramente sus gestos, debe aparecer durante al menos el 95% del tiempo, y debe ocupar al menos el 10% de la superficie del cuadro. Usted debe hablar mirando a la cámara.
- En el video a Michelina Porto:
    - No puede exceder de 30 segundos la presentación del problema.
    - No debe explicar el significado de los términos de Ciencia de Datos, Michelina Porto ya los conoce.
    - Debe quedar clara la justificación de cada decisión tomada, si obedece a resultados de experimentos previos o a algún tipo de dogma revelado.
    - Es fundamental que narre los experimentos que le dieron resultados sub óptimos, esa es la forma en que el equipo aprende.

Rúbrica Videos Presentación	
Porcentaje	**Concepto a Evaluar**
10%	Entretenimiento. La video presentación es apasionante y no hay sección que aburra, son 5 minutos de pura adrenalina.
10%	Audiencia. La video presentación tiene totalmente en cuenta la audiencia a la cual está dirigida y saca provecho de las características únicas de esa audiencia.
30%	Historia . La presentación narra una historia, hay una clara introducción con un "gancho" que invita a ver el video, un desarrollo adecuado con una continuidad argumental lógica y un desenlace concreto. La narrativa está organizada en torno a las etapas de la pirámide de Freytag o estructura de similar complejidad donde la *emoción* y la *sorpresa* juegan un papel fundamental.
25%	Consistencia del contenido. Lo presentado refleja fielmente el conocimiento descubierto en los experimentos efectivamente realizados y las conclusiones están sustentadas en datos que aparecen presentados adecuadamente.
25%	Originalidad del contenido. Las ideas presentadas son originales, ingeniosas, basadas en una profunda comprensión del problema y su solución.

Cada alumno debe hacer dos video presentaciones, es una tarea individual. Por más que se haya formado grupo de dos personas para la/s competencia/s de la asignatura, los videos deben ser distintos así como el material que los soporta.

La entrega de los videos se hace por Zulip, enviando un mensaje al Stream **z-entregafinal** que se disponibilizará a su debido tiempo. El mensaje deberá contener un link de acceso público que no haga falta ni usuario ni password ni estar registrado en ninguna plataforma para quienes lo vean.

Los formatos preferidos para los videos son: YouTube, Prezi, Loom y Twitch. No se acepta la entrega de links a Google Drive o Dropbox. El video debe ser accesible para todos por lo menos hasta cinco meses después de haber sido entregadas las notas, para que tengan acceso a todos ellos los alumnos que deben realizar el recuperatorio de la materia.

Es parte fundamental de la tarea que los alumnos investiguen la forma de hacer una video presentación efectiva e intercambien ideas en Zulip. Ese descubrimiento será asistido por los profesores.

La calificación de los videos se realizará mediante un Torneo de Videos en donde votarán alumnos *y también profesores*, normalizando los puntajes obtenidos al intervalo [0, 10]. Se tomarán los recaudos para garantizar el más alto grado de imparcialidad en las votaciones, como por ejemplo, no se podrá ser juez de un duelo de videos donde participan personas con las que se ha formado grupo.
Habrá una nota para el video a Michelina Porto y otra nota al video a Miranda Wintour.

1.5.5 Evaluación Individual

Esta instancia de evaluación individual es obligatoria para todos los alumnos, presencial, el día estipulado en el cronograma, y se presenta en dos formatos mutuamente excluyentes:

- examen oral individual
- examen escrito individual

en ambos casos los alumnos deberán responder preguntas personalizadas sobre cómo hicieron la predicción de la Ultima Competencia. No se realizan preguntas teóricas. El objetivo es garantizar que el alumno realmente sea autor del trabajo de la Ultima Competencia y conoce a la perfección cada parte de su código y ha sido él quien criteriosamente ha tomado cada una de las decisiones.

Aún en el caso que la Ultima Competencia fue realizada en un grupo de dos personas, ambas personas deberán conocer a la perfección todos los aspectos de la solución presentada y haber participado activamente en la toma de todas las decisiones de construcción del modelo. En el caso que ambos integrantes rindan examen oral, será individual.

En el Examen Escrito no se podrá disponer de ningún artefacto electrónico: teléfonos móbiles, laptops, smartwatches, anteojos inteligentes, etc los que se deberán dejar sobre el escritorio del aula de examen. El Examen Escrito deberá ser escrito de puño y letra en hojas de papel.

En el Examen Oral, el alumno deberá tener su laptop con acceso offline al código con el que ha generado el submit de la Ultima Competencia, ya que se le podrá pedir que explique detalles del mismo. No podrá acceder a teléfonos móbiles, smartwatches, anteojos inteligentes, ni tampoco tendrá conexión a internet desde su laptop.

En ninguno de los casos podrá acceder a inteligencia artificial generativa del tipo LLM (ChatGPT, Claude, etc)

El dia del examen, minutos antes del comienzo, cada alumno será notificado sobre la modalidad oral o escrita de su examen.

Más allá de la evaluación individual, la segunda competencia debe ser realizada con notebooks/scripts que impliquen un aporte significativo a los notebooks brindados por la cátedra. No es aceptable que la solución final sea la corrida de un notebook con el simple cambio de la semilla primigenia.

1.6 Misión de la Asignatura

Intentar que l@s estudiantes se enamoren de la ciencia de datos.
Lograr que los alumnos sean capaces de resolver un problema de dimensiones reales del mercado argentino con una *excelencia* que sorprenda a sus pares.

Despertar la llama de la pasión sostenible por explorar con espíritu crítico nuevos saberes.

1.6.1 Objetivos de la Asignatura

1. Resolver un problema de dimensiones reales del mercado local utilizando las herramientas tecnológicas para manejar grandes volúmenes de datos y ser capaz de generar una predicción competitiva.
2. Aplicar en forma práctica a un problema concreto con datos reales los conocimientos vistos en las materias teóricas de los cuatrimestres anteriores, enfrentando eficazmente todas las etapas del data mining.
3. Desarrollar una fuerte cultura de la experimentación siendo capaz de cuestionar todo lo que le han enseñado.
4. Desarrollar la creatividad para el Feature Engineering
5. Conocer y utilizar efectivamente las técnicas “estado del arte” en cuanto a
    1. Algoritmos y librerías de última generación de modelado predictivo sobre datos estructurados
    2. Optimización de hiperparámetros
    3. Interpretación de modelos predictivos
    4. Metodología Machine Learning Operations
    5. Procesamiento de grandes volúmenes de datos en la nube

1.7 Unidades Temáticas

1. Nociones elementales de la actividad bancaria, ciclo de vida de un cliente, valor vida de un cliente, retención de clientes, campañas de marketing directo.
2. Metodologías CRISP, Six sigma y SEMMA.
3. Comparación de modelos predictivos
    1. El problema de las múltiples comparaciones
    2. Estimación Montecarlo
    3. Validación Cruzada
4. Curva ROC, concepto de área bajo la curva AUC
5. Breve reseña de Árboles de Decisión y de Árboles de Estimación de Probabilidad.
6. Tratamiento de datasets desbalanceados
7. Optimización de hiperparámetros
    1. Red de Búsqueda (Grid Search)
    2. Optimización Bayesiana
8. Métodos de Ensamblado de Modelos Predictivos
    1. Voting
    2. Bagging
    3. Boosting
    4. Stacking
9. Algoritmos de Ensemble
    1. Random Forest
    2. Gradient Boosting of Decision Trees
        1. XGBoost (año 2016)
        2. LightGBM (año 2017)
        3. CatBoost (año 2018)
        4. NGBoost (año 2019)
10. Ingeniería de Atributos (Feature Engineering)
    1. Tratamiento de nulos
    2. Selección de variables
    3. Variables derivadas, el problema de los cortes paralelos de los árboles de decisión.
    4. Incorporación de variables históricas
11. Metodología de Walk Forward Validation
12. Interpretación de predicciones por el método “Explicaciones Locales Aditivas de valores Shapley”

13. Clustering Jerárquico basado en la distancia derivada de Random Forest
14. Nociones básicas de MLOPs
    1. Administración de datos
    2. Plataforma de Experimentación
    3. Puesta en producción
    4. Monitoreo
15. Nociones básicas de Storytelling
    1. armado de una narración, Pirámide de Freytag, Camino del Héroe de Joseph Campbell
    2. buenas prácticas para el armado de gráficos
    3. buenas prácticas para el armado de video presentaciones

1.7.1 Tecnologías a enseñar y reforzar

- Lenguajes Python, R, SQL
- Vibe Coding
- Plataforma Jupyter Lab
- Control de versiones de código Git y GitHub
- Plataforma open source de MLOps : MLFlow
- Procesamiento en Google Cloud, creación de máquinas virtuales, imágenes del sistema operativo, instancias spot
- Rudimentos de la terminal de Linux
- Docker
- Control de Versiones de Datos Git LFS

1.8 Bibliografía General de la Asignatura

La siguiente es la bibliografía general; en cada clase se brindará bibliografía específica sobre los temas vistos.

Libro de cabecera https://hastie.su.domains/ElemStatLearn/

Hastie, T, Tibshirani, R. Friedman, J. *The Elements of Statistical Learning*, Second Edition, Springer Series in Statistics, Springer, 2017

Sitios con muy buenos artículos

https://machinelearningmastery.com/ muy precisos los artículos de Jason Brownlee

https://www.kdnuggets.com/

Sitios populares fáciles de leer que hay que tomar con pinzas sus artículos ya que por lo general carecen de profundidad, y lo que es muy grave hay muchos con enormes errores conceptuales y prácticos:

https://towardsdatascience.com/

https://medium.com/tag/data-science

Papers y otros Libros

Chen, Tianqui, XGBoost: A Scalable Tree Boosting System, *Proceedings of the 22Nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794. ACM, 2016.

Duan, Tony, NGBoost: Natural Gradient Boosting for Probabilistic Prediction, *Proceedings of the37thInternational Conference on Machine Learning*, 2020

Fawcett, Tom, ROC Graphs: Notes and Practical Considerations for Data Mining Researchers. *Technical Report HPL-2003-4*, HP Labs, 2003.

Flach, Peter Putting Things in Order, On the fundamental role of ranking in classification and probability estimation. , *18th European Conference on Machine Learning*, 2007

Gareth, James, An Introduction to Statistical Learning with Applications in R, *Springer Texts in Statistics*, *Springer*, 2017

Guo, P, Kim, Jm Rubin, R, How video production affects student engagement: An empirical study of MOOC videos, Proceedings of the first ACM conference on Learning @ scale conference, 2014

Hastie, T, Tibshirani, R. Friedman, J. *The Elements of Statistical Learning*, Second Edition, Springer Series in Statistics, Springer, 2017

He, K.; Zhang, X.; Ren, S.; Sun, J. Deep residual learning for image recognition. In Proceedings of the Conference on Computer Vision and Pattern Recognition, Las Vegas, NV, USA, 30 June 2016.

Ke, Guolin, LightGBM: A Highly Efficient Gradient Boosting Decision Tree, *NIPS'17: Advances in Neural Information Processing Systems Conference*, 3148-3156 , 2017

Krizhevsky, A.; Sutskever, I.; Hinton, G.E. Imagenet classification with deep convolutional neural networks. Commun. ACM **2017**, 60, 84–90.

Knaflic, C. (2015). Storytelling with data : a data visualization guide for business professionals . Hoboken, New Jersey: Wiley.

Kuhn, Max, Feature Engineering and Selection: A Practical Approach for Predictive Models *Chapman&Hall/CRC Data Science Series*, 2019

Imani, M.; Arabnia, H.R. Hyperparameter optimization and combined data sampling techniques in machine learning for customer churn prediction: A comparative analysis. *Technologies* 2023, *11*, 167.

Lundberg, Scott, A Unified Approach to Interpreting Model Predictions, *31st Conference on Neural Information Processing Systems*, 2017

Pang-Ning Tan, Introduction to Data Mining second edition, *What's New in Data mining Series*, Pearson, 2018

Pearl, Judea, Causality, Models, Reasoning and Inference, *Cambridge University Press*, 2009

Piotr Skalski, David Sutton, Stuart Burrell, Iker Perez, and Jason Wong. 2023. Towards a foundation purchasing model: Pretrained generative autoregression on transaction sequences. In Proceedings of the Fourth ACM International Conference on AI in Finance. 141–149.
Provost, Foster, Robust Classification for Imprecise Environments. *Proceedings of the Fifteenth National Conference on Artificial Intelligence* (pp. 706-713). Menlo Park, CA: AAAI Press, 1998.

Prokhorenkova, Liudmila, CatBoost: unbiased boosting with categorical features, *NIPS'18: Proceedings of the 32nd International Conference on Neural Information Processing Systems*, 2018

Raj, E, Engineering MLOps: Rapidly build, test, and manage production-ready machine learning life cycles at scale, Packt Publishing, 2021

Reshef, David, Detecting Novel Associations in Large Datasets, *Science* 2011, Vol. 334 no. 6062 pp. 1518-1524, 2011

Rokach, L, Ensemble Learning: Pattern Classification Using Ensemble Methods, Second Edition, Series in Machine Perception and Artificial Intelligence, WSPC, 2019

Salzberg, Steven, On Comparing Classifiers: Pitfalls to Avoid and a Recommended Approach. *Data Mining and Knowledge Discovery Journal*, Kluwer Academic Publishers, 1, 317-327. 1997.

Zhao, X.; Liu, Y.; Zhao, Q. Improved LightGBM for extremely imbalanced data and application to credit card fraud detection. *IEEE Access* 2024, *12*, 159316–159335.
Z.-H. Zhou, Ensemble methods: foundations and algorithms, Second Edition, *Chapman and Hall/CRC*, 2025.

Para la búsqueda de papers se recomienda primero buscarlos en Google Scholar https://scholar.google.com/ y si no está disponible bajarlo del inframundo https://sci-hub.ru/

Página para bajar libros https://annas-archive.pk/

Herramienta para visualizar conexiones entre papers https://www.connectedpapers.com/

2 Metodología de Enseñanza

2.1 Generalidades

Basados en el authentic learning se plantea un problema de negocios de la vida real tal cual se podría encontrar en una empresa en Argentina, con una cantidad de datos real, y una forma de evaluación igual a la que el proyecto sería evaluado en una empresa : ganancia en pesos argentinos de la campaña de retención de clientes y exposición de los resultados con storytelling.
La asignatura se dicta con el espíritu de la teoría del conectivismo, donde los alumnos deben crear colaborativamente contenido, reflexionar sobre el contenido de sus pares y tutores, discutirlo y de esa forma generar nuevo contenido.

La dinámica de las clases presenciales (opcionales) es la del flipped classroom (aula invertida) donde los alumnos ven los materiales *más simples* y hacen experimentos asincrónicamente **antes** de la clase sincrónica, y una vez en la clase sincrónica se utiliza una dinámica de active learning basado en pares, más algunas exposiciones de los profesores para los temas más complejos. Dado que los alumnos pueden consultar por Zulip en forma asincrónica antes de la clase, técnicamente el nombre correcto de la metodología es *active learning forte*.

Las tutorias son encuentros virtuales (mandatorios) de un tutor y tres estudiatnes a los que el/la estudiante llegan a recibir retroalimentación personalizada de sus avances del proyecto de predicción.

2.2 Manifiesto Pedagógico

Si una sola frase debiera resumir la pedagogía de esta asignatura sería la expresión de Plutarco :
Enseñar, más que llenar un recipiente es encender un fuego.

Similarmente, si la pedagogía de esta asignatura sigue el siguiente video de Seymour Papert (46 segundos)
https://www.youtube.com/watch?v=9qj1E-uhFYc

Las filosofías pedagógicas se pueden dividir a grandes rasgos en estas teorias antagónicas:

- el **conductismo- instructivismo** de Edward Thorndike y B. F. Skinner que es la predominate en el mundo y Argentina
- el **constructivismo social** de John Dewey y Seymour Papert que será utilizada en esta asignatura.

El estilo en esta asignatura es el del *aprendizaje basado en pares*, en donde a pesar de existir un sendero diseñado por los profesores se alienta continuamente a los alumnos a recorrer su propio camino, observar, valorar y aprender de sus pares, diseñar creativamente sus propios experimentos reflexionando profundamente sobre los resultados que se van obteniendo, cuestionando al establishment. Como referencia se puede tener la filosofía y comunidad que existe alrededor del lenguaje de programación Scratch y los conceptos de experiencias educativas de Mitchel Resnick.

La asignatura es una experiencia de gran intensidad intelectual y emocional que busca constantemente alentar a que cada alumno supere lo que se espera de él; se intenta lograr un efecto de resonancia grupal que amplifique el aprendizaje.

El estilo de dictado está basado en la frase "la emoción es el timón de la razón" donde cada tema es

presentado de forma que genere gran emocionalidad en los alumnos, por momentos usted sentirá profundo amor y fascinación por las ideas que se estarán viendo, en otros literalmente sentirá odio.

Finalmente, aunque no menos importante, la asignatura busca la reflexión profunda y el cuestionamiento crítico de lo enseñado en otras asignaturas e incluso en ella misma. Citando a Richard Feynman

"The problem is not people being uneducated. The problem is that people are educated just enough to believe what they have been taught, and not educated enough to question anything from what they have been taught".

Dos videos y un artículo que reflejan aspectos de la forma de enseñanza

https://www.youtube.com/watch?v=uRxD-pe3PN0 Mitchel Resnick, Lifelong Kindergarten Group, Media Lab, MIT

https://web.media.mit.edu/~mres/papers/constructionism-2014.pdf Mitchel Resnick, Construtionism

https://www.youtube.com/watch?v=yx5VHpaW8sQ George Siemens, Connectivism

2.3 Pensamiento Creativo – Tinkering

Para ilustrar lo que se espera del alumno en esta asignatura, van unos párrafos del libro Resnick, Mitchel , *Lifelong Kindergarten: Cultivating Creativity through Projects, Passion, Peers, and Play*, The MIT Press, 2018

One of the students, named Nicky, started by building a car out of LEGO bricks. After racing the car down a ramp several times, Nicky added a motor to the car and connected it to the computer. When he programmed the motor to turn on, the car moved forward a bit—but then the motor fell off the body of the car and began vibrating across the table on its own.
Rather than trying to repair the car, Nicky became intrigued with the vibration of the motor. He played and experimented with the vibrating motor, and began to wonder whether he might be able to use the vibrations to power a vehicle. Nicky mounted the motor on a platform atop four “legs” (LEGO axles).
After some experimentation. he realized that he needed some way to amplify the motor vibrations.
To do that, he drew upon some personal experiences. Nicky enjoyed riding a skateboard, and he remembered that swinging his arms gave him an extra push on the skateboard. He figured that a swinging arm might accentuate the vibrations of the motor as well, so he connected two LEGO axles with a hinged joint to create an arm and attached it to the motor. As the motor turned, the arm whipped around—and amplified the motor vibrations, just as Nicky had hoped. In fact, the system vibrated so strongly that it frequently tipped over.
A classmate suggested that Nicky create a more stable base by placing a LEGO tire horizontally at the bottom of each leg. Nicky made the revision, and his “vibrating walker” worked perfectly. Nicky was even able to steer the walker. When he programmed the motor to turn in one direction, the walker vibrated forward and to the right. When he programmed the motor to turn in the other direction, the walker vibrated forward and to the left.

I was impressed with Nicky’s vibrating walker—but even more impressed by the strategies he used in creating it. As Nicky worked on his project, he was constantly tinkering. Throughout the process, he was playfully experimenting, trying out new ideas, reassessing his goals, making refinements, and imagining new possibilities.

Like all good tinkerers, Nicky was:

•**Taking advantage of the unexpected.** When the motor fell off of his car, Nicky didn't see it as a sign of failure; he saw it as an opportunity for new explorations.

•**Drawing on personal experience.** When Nicky needed to amplify the vibrations of the motor, he relied on his experiences as a skateboarder and knowledge of his own body.

•**Using familiar materials in unfamiliar ways.** Most people don't imagine LEGO axles as arms or legs, nor do they imagine LEGO wheels as feet—but Nicky was able to look at objects in the world around him and see them in new ways.

Usted no jugará con bloques de un LEGO , sino que configurará y reconectará scripts y bloques de código brindados por la cátedra, y si tiene la fortuna de ser atrapado por el entusiamo y motivación de Nicky, desarmará scripts y creará algo totalmente iinnovador.

2.4 Dinámica Constructivista en el Aula

En caso de preguntarse cómo concretamente difieren el conductismo del constructivismo, aquí va un ejemplo de dinámica sobre como medir para niños de 6 años

- https://storage.googleapis.com/open-courses/videos-d0a6/whale_measuring.mp4 (4 minutos)
  Schifter, Deborah, A constructivist perspective on teaching and learning mathematics, Phi Delta Kappan; Bloomington Vol. 77, Iss. 7, (Mar 1996): 492-499

Sin embargo esta dinámica en el aula puede ser muy dificl para algunos alumnos adulto, ya que suele estar acostumbrado a la "Educacion Colonial" https://storage.googleapis.com/open-courses/videos-d0a6/colonial_education.mp4 (1 minuto) y esperar "recetas" del profesor.

2.5 Authentic Learning

El enfoque pedagógico de esta asignatura está fuertemente relacionado con el *Authentic Learning* e indirectamente al Constructivismo Social en cuanto a:

- El aprendizaje comienza con el planteo de un problema del mundo real, de dimensiones reales, que la mayoría de alumnos muy probablemente deban enfrentar su actividad profesional.
- Algunos aspectos del problema están intencionalmente definidos de forma difusa para que los alumnos reflexionen profundamente sobre las mejores soluciones posibles.
- La evaluación de la asignatura refleja la evaluación del mundo real profesional, basada en la rentabilidad, comunicación de resultados y colaboración con pares.
- La teoría está al servicio de la práctica, y aparece justo a tiempo; jamás a la inversa.
- El profesor colabora con *Instructional Scaffolding* ayudando a escalar los distintos niveles de complejidad conceptual.

2.6 Flipped Classroom Forte

La idea es que el alumno reciba la ayuda directa del profesor en los momentos de aprendizaje que más lo

necesita que generalmente es cuando el alumno se enfrenta a resolver un problema en soledad (no en el aula); para generar esa disponibilidad de ese tiempo lo fácil, la transmisión de información, se pasa para antes de la clase en modalidad asincrónica, cuando los profesores no están disponibles en tiempo real.

Además se evalúa lo asincrónico con quizzes y con las submits a las competencias, permitiendo a los profesores responder por el foro/chat Zulip preguntas simples, y dejar lo que no ha sido entendido para reforzarlo en la siguiente clase presencial. Los quizzes muestran que se está entendiendo y que no, por más que el alumno crea que está entendiendo todo lo que lee.

Una presentación sobre Flipped Learing Forte clara, concisa y carente del usual laberinto literario de las ciencias sociales, es https://www.slideshare.net/alfredo.prietomartin/intercambio-hispano-chileno-de-experiencias-de-flipped-learning-en-enseanza-blended-y-online junto con este artículo https://revistaventanaabierta.es/flipped-classroom-sus-limitaciones-y-aparicion-de-una-nueva-variante-flipped-learning-forte/

2.7 Conectivismo

Las ideas da teoría del aprendizaje del conectivismo tienen gran semejanza con el deep learning, https://www.youtube.com/watch?v=yx5VHpaW8sQ (3 min)

- El aprendizaje ocurre a traves de la red neuranal del cerebro, redes de humanos y redes de entidades no humanas.
- La red de conocimento se desarrolla a partir de las interacciones con otras entidades de la red y el mundo en general. El objetivo de la enseñanza es estimular dichas interacciones.
- La red crece:
  - nodos
    - incorporando nuevos nodos
    - eliminado nodos ya no útiles
  - conexiones entre nodos
    - creando conexiones entre nodos que antes no estaban conectados
    - reforzando la conexción entre dos nodos, al ser transitado frecuentemente
    - disminuyendo el peso de la conexión, al ser poco transitado ese link
- El conocimiento reside en los pesos de las conexiones
- Aprender es el proceso de conectar nodos específicos o fuentes de información
- La capacidad de aprender cosas nuevas es más importante de lo que se ya se conoce.
- Tomar decisiones es un proceso de aprendizaje, de transitar reiteradamente y en formas novedosas la red

2.8 Active Learning

Active Learning significa que se llevará al mínimo lo que en la jerga se denomina "clase magistral" que es básicamente un profesor hablando y los alumnos escuchando; los alumnos se deberán involucrar activamente durante la clase sincrónica con actividades diseñadas y guiadas por el profesor, en donde

deban reflexionar profundamente sobre el tema que se está viendo en clase.

Active Learning es *la metodología* en la que toda la comunidad educativa está de acuerdo que brinda resultados superadores. Puede verse este artículo "Active learning increases student performance in science, engineering, and mathematics" https://www.pnas.org/doi/full/10.1073/pnas.1319030111

Es tan distinto a la mecánica tradicional que muchos alumnos se sentirán incómodos al comienzo porque jamás han sido expuestos a la misma. No se confunda, active learning no tiene que ver con ser extrovertido, sino con ser reflexivo !!

Videos cortos que explican los fundamentos del active learning:

https://www.youtube.com/watch?v=zoa2pKYp_fk Janet Rankin, MIT

https://www.youtube.com/watch?v=Z9orbxoRofI Eric Mazur, Harvard University

Un artículo sobre aulas de active learning https://er.educause.edu/articles/2017/12/creating-active-learning-classrooms-is-not-enough-lessons-from-two-case-studies

Esta es una lista de ejemplo *no vinculante* del tipo de actividades que se llevarán a cabo (ir a Large Group) https://www.queensu.ca/teachingandlearning/modules/active/12_exmples_of_active_learning_activities.html siendo la actividad más tradicional el Think Pair Share que es la que habla Eric Mazur

Al siguiente extenso video es una clase en el MIT donde en un posgrado de educación la profesora demuestra a los alumnos diversas dinámicas de active learning https://www.youtube.com/watch?v=hGBNi4P9OfA , no hace falta que lo vea, ya lo experimentará.

2.9 Evaluación Continua

Habrá notado que la asignatura, en lugar de un gran examen o proyecto final, cuenta con varias pequeñas instancias minuciosamente detalladas de evaluación, distribuídas a lo largo de todo su desarrollo. Usted conoce exactamente cómo será evaluado, y las etapas de evaluación son pensadas para ayudarle en la subida de los andamios.

De cada competencia aprenderá qué es lo que funciona y que no y deducirá como elegir un modelo que consistentemente funcione bien en datos nuevos del futuro. Cada competencia pone en práctica un conjunto específico de algoritmos y técnicas, de los resultados de cada competencia usted tendrá claro qué conocimientos deberá reforzar para el siguiente desafío y los profesores lo ayudarán en el proceso.

El participar del torneo de videos dirigidos a la directora comercial Miranda Wintour, le permitirá observar la forma en que exponen sus compañeros, las herramientas que utilizan, y el feedback que le darán los profesores le servirá para generar un video muy superador para la gerenta de business intelligence Michelina Porto.

El participar en la tarea de "Experimentos Colaborativos", que dura varias semanas, lo retroalimentará continuamente sobre las mejores decisiones para la construcción de un excelente modelo predictivo. Usted recibirá feedback de sus compañeros y profesores sobre los problemas que deba resolver y experimentos que le corresponda realizar.

Durante el transcurso de la asignatura se le dará retroalimentación sobre lo relevante que está siendo su participación en el foro/chat Zulip, y se lo alentará continuamente a contribuir a la comunidad.

Todo lo anterior, debido a que facilita que el alumno lleve al día la asignatura, permite intervenir a tiempo en las debilidades, evitará que pierda el hilo de la enseñanza, y aumentará para muchas personas la probabilidad de aprobar.

Siempre habrá alumnos que no necesitan que les enseñen, sino simplemente que les indiquen qué vale la pena aprender primero.

3 Abróchense los cinturones

En la materia trabajaremos con una gran variedad de herramientas, plataformas y conjuntos de datos, las que deben ser instaladas, configuradas, interconectadas y finalmente usted deberá aprender a utilizarlas. No se sienta desbordado por el shock inicial, aprenderá a utilizarlas. En palabras de un ex alumno "todas las semanas tuve en simultáneo la frustración de no entender alguna implementación y la satisfacción de dominar lo que una semana atrás parecía imposible."

Intente avanzar por su cuenta con los siguientes pasos de instalación, aunque no entienda en detalle lo que está haciendo, ya se le explicará el uso de las herramientas en clase.
En caso de tener dificultades con algún punto, o consúltelo en Zulip o espere a la primera clase en donde se verán conceptualmente estos pasos.

Palabras de un ex alumno : "Unos pocos empezamos la maestría con PC de Empresa con restricciones, bloqueos y rigideces. La fuimos "piloteando" pero cada vez se fue haciendo más cuesta arriba... Creo que en esta materia finalmente todos terminamos con PC libre. En mi caso fue un salto cuántico de comodidad."

3.1 Alta en Plataformas

3.1.1 Zulip herramienta de chat y foros discusión

En la materia no se utilizará el email, toda la comunicación y discusión se llevará a cabo en Zulip. Los profesores serán por lejos quienes más participen en las conversaciones de Zulip.

Para darse de alta en el Zulip de la materia usted debe ingresar al link de Zulip de la sección 1.1 Links Fundamentales y presionar el link de **Sign Up** o Regístrese (abajo a la derecha del recuadro)

Usted puede acceder a Zulip de tres formas:

- En su PC desde algun browser
- En su PC utilizando la app, instálela desde https://zulip.com/apps/
- Desde su smartphone, busque la app en su *App Store* (alerta : no es buena la app)

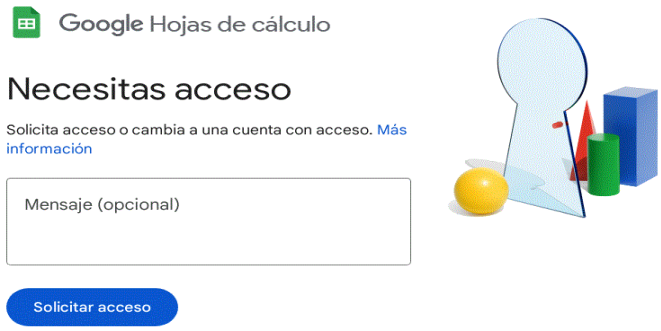
En el capítulo Herramientas, Conceptos y Operación se le enseñará cómo utilizar efectivamente Zulip a lo largo de la asignatura, ya que parte de la nota final depende de ello.

Una vez dentro de Zulip, vaya a la rueda dentada ubicada arriba a la derecha, Manage streams, elija el stream `cartelera`, y a la derecha marque Email notifications

3.1.2 Comisión Jueves : Google Sheet Colaborativa de la Asignatura

Para proceder con este paso es necesario que usted deberá contar con una cuenta de gmail la que además le será indispensable para trabajar con la plataforma Google Cloud.

Siga el link de Google Sheet Colaborativa de la sección 1.2 Links Fundamentales de este documento.
Le aparecerá una pantalla de este estilo



presione el boton de Solicitar acceso , a las pocas horas recibirá un email en su gmail informándole que ya tiene acceso a la planilla colaborativa, en donde deberá ir cargando resultados de las corridas que realice a lo largo de la asignatura y podrá comparar sus resultados con los de sus compañeros.

3.1.3 Plataforma Hypothes.is

Hypothes.is es una herramienta de anotación colaborativa de páginas web y documentos .pdf, que también utilizaremos para anotar scripts y Jupyter Notebooks . Le permitirá ver anotaciones que el profesor ha realizado en papers a utilizar en la asignatura, y usted mismo podrá agregar anotaciones.

La siguiente es una razonable introducción a Hypothes.is https://www.youtube.com/watch?v=87h0nYi-i9o presta atención a cómo se hacen las anotaciones y a cómo se participa en una discusión sobre una anotación.

Ir a la página https://web.hypothes.is/start/ y seguir los pasos para crear un usuario, se recomienda enfáticamente crear un usuario con el formato que sea <su nombre> punto <su apellido> .
Adicionalmente instale la extensión para el navegador Google Chrome (la que podrá utilizar también en Brave), que le será indispensable para la anotación de documentos .pdf

No haremos públicas las anotaciones en la asignatura, sino que las acotaremos al grupo privado `dmeyf`, para sumarse a estos grupos estando logueado a `Hypothes.is` en su browser y luego seguir este link https://hypothes.is/groups/oZ5iroYw/dmeyf

3.1.4 Plataforma ChatGPT/Claude

Utilizaremos el novedoso ChatGPT para que explique que hacen los scripts provistos por la cátedra y si tenemos suerte escriba scripts simples por nosotros.
Ingrese a https://chat.openai.com/auth/login y cree un usuario gratuito. Dada la alta demanda de ChatGPT es posible que deba probar en distintos horarios hasta lograrlo.

3.1.5 Plataforma GitHub

Para poder compartir nuestros scripts y experimentos habrá un repositorio oficial de la asignatura y uno suyo personas, ambos residirán en la nube. Para ello usted dará de alta una cuenta en los servicios de la plataforma GitHub

Registrarse en https://github.com/signup?ref_cta=Sign+up

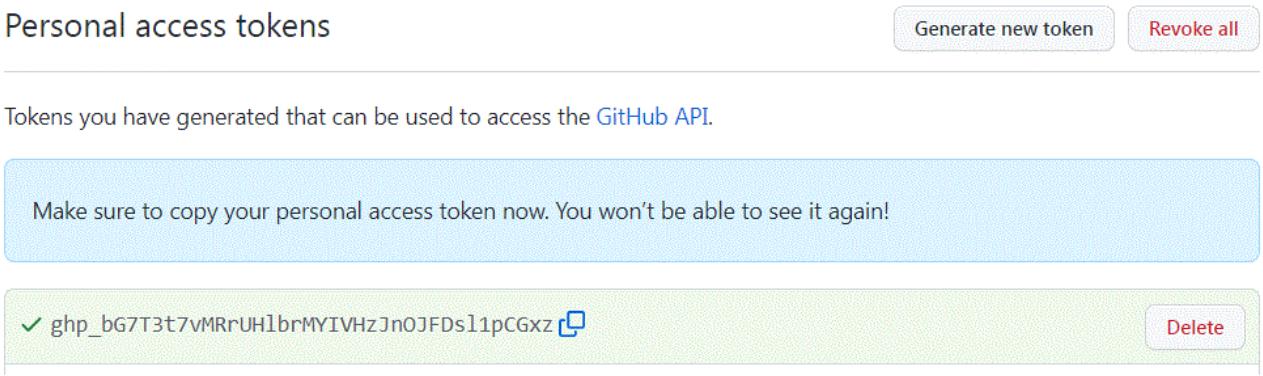
Una ayuda simple es https://www.classicpress.net/github-desktop-a-really-really-simple-tutorial/

Una vez ya registrado y dentro de su sesión de GitHub, es momento de crear su Personal Access Token que será algo así como su usuario y clave para acceder desde su PC local y desde Google Cloud.

Dentro de su sesión de GitHub vaya a la página https://github.com/settings/tokens , elija la opcion que está a la izquieda de la pantalla `Tokens (classic)` y presione el botón que está a la derecha de la pantalla `Generate new token (classic)`

- donde dice Note escriba "mi primer token",
- en Expiration marque Custom y elija como fecha el 31-dic-2026 (realmente es muy recomendable que ponga una fecha de expiración)
- luego en Select Scopes marque TODOS los recuadros que le aparecen
- al final de la página presione el botón Generate Token

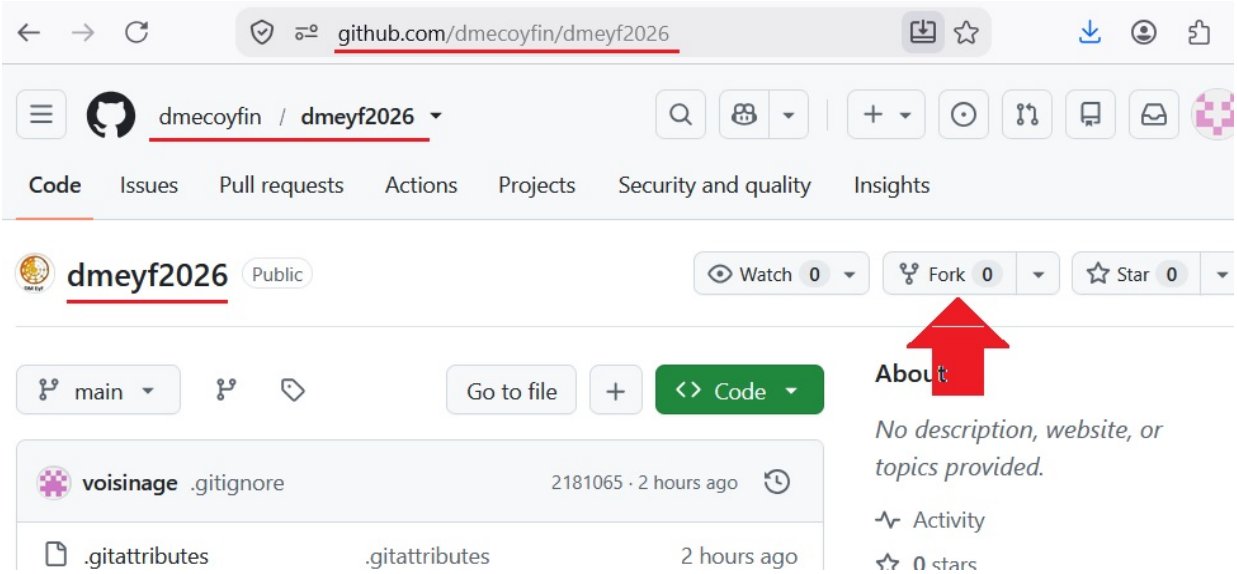
Le aparecerá una pantalla como esta:



allí copie y guarde en un lugar seguro el token, que en el ejemplo de la imagen es el string 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

usted volverá a utilizar ese token cuando instale Google Cloud, guárdelo en un lugar seguro por favor

Una vez hecho el login a su GitHub usted no tendrá ningún repositorio creado inicialmente, ir al repositorio GitHub de la materia cuyo link está en el capítulo *Links Fundamentales* y hacer un fork del repositorio presionando el botón que está arriba a la derecha de la página de GitHub . Por favor NO cambie el nombre del repositorio.



Le aparecerá un formulario para crear el fork

De esta forma usted pasará a tener en su cuenta de GitHub una copia del repositorio oficial de la asignatura. Ambos están en la nube, pero usted no puede trabajar directamente con esos archivos en la nube sino que debe generar una copia en su computadora de **su** repositorio GitHub local.

3.1.6 Check In a la Asignatura en Zulip

Para los profesores es muy importante conocer quién es usted de forma de personalizar los mensajes en Zulip, recomendar lecturas personalizadas acordes a su formación, experiencia e intereses. Adicionalmente, el CheckIn sirve para conocer a sus compañeros, en particular con el alto grado de virtualidad que ha tenido el primer cuatrimestre.

Enviar un gran mensaje Zulip al channel `#z-CheckIn` topic `CheckIn` con los siguientes puntos (recuerde que es público)

1. Identificación
    1. Nombre y Apellido
    2. Linkedin
    3. Usuario GitHub.com
    4. Edad
2. Estudios previos
    1. Carrera de grado, Universidad, año de graduación

2. Posgrados realizados o en curso (no incluya a este posgrado...)
3. Educación previa en ciencia de datos (Coursera, edX, Udemy, Digital House, etc) detalle

3. La vida más allá de *Cero + Infinito*
    1. ¿Cuál fue el artista que más escuchó en su Spotify Wrapped 2025? Si no utiliza Spotify, mencione el artista o grupo que más escuchó durante el último año.
    2. ¿Qué comida o ingrediente le resulta irresistible?
    3. ¿Qué actividad, hobby, habilidad o rasgo importante de su vida sería imposible descubrir leyendo su LinkedIn?
    4. Tuvo alguna cábala durante el mundial de fútbol 2026? Cuál? si tuvo más de una elija la que mejores resultados le dio.
    5. ¿Hubo algún tema, actividad, objeto o fenómeno con el que se haya obsesionado particularmente durante el último año? ¿Cuál?
4. Cursada de esta maestría
    1. Del cuatrimestre anterior, relate en gran detalle alguna actividad de una materia que logró despespertar en usted pasión. ¿Cómo interactuó con esa actividad?
    2. ¿Qué materias de la maestría está cursando en este cuatrimestre en paralelo a DMEyF?
5. Experiencia laboral
    1. ¿Posee experiencia docente? explíquela
    2. ¿A que se dedica en su trabajo actual? ¿Trabaja en ciencia de datos o en algo relacionado? En caso afirmativo detalle.
    3. ¿En su trabajo actual tiene profesionales (o equivalente) que le reportan directamente a usted?
    4. ¿Cuántas horas ha dedicado a programar en algún lenguaje en lo que va del año 2026, sin tener en cuenta este posgrado? Relate lenguajes y tareas.
    5. ¿Detalle el uso que da a LLMs (Claude , ChatGPT, Gemini, etc) en su actividad profesional y académica? ¿Qué uso le da para programar?¿Paga mensualmente alguna de las herramientas?

6. ¿Cómo prefiere aprender usted, como el hijo o como la hija de Feynman? Vea el siguiente video de Richard Feynman, ganador del Premio Nobel por sus aportes en Física Cuántica, considerado el mejor profesor del siglo XX ttps://www.youtube.com/watch?v=BY6VntTmtIo
7. ¿Tiene experiencia en la metodología y realización de experimentos, ya sea de ciencias naturales, físicas, o simulaciones informáticas?
8. Primero lea en detalle https://subscription.packtpub.com/book/business-and-other/9781787287037/1/ch01lvl1sec13/12-developer-learning-curve-why-learning-how-to-code-takes-so-long

    y luego relate su experiencia con lenguajes/entornos de programación/algoritmos
    1. lenguaje R
    2. Tidyverse y dplyr en R
    3. data.table en R

4. Git / GitHub
5. Cloud Computing (Google Cloud, Azure, AWS, ...)
6. lenguaje Python
7. lenguaje Julia
8. SQL
9. Sistema operativo Linux
10. Árboles de Decisión
11. Gradient Boosting (XGBoost/LightGBM)
12. Utiliza algún entorno en particular de R (Rstudio, R Base, etc)
13. Utiliza algún entorno en particular de Python (VS Code, PyCharm)

9. Elija CINCO números primos, 100003 < p < 999983 , intentando que sus números no se solapen con los que elijan sus compañeros de curso. Serán utilizados como *sus* semillas de generadores números pseudoaleatorios a lo largo de la asignatura.

10. Aqui le haremos meditar profundamente.
    Enviar un gran mensaje Zulip al channel `#z-CheckIn` topic `Pregunta Trascendental` usando el formato < Contexto, Pregunta>

    a partir de lo cursado en la primera mitad del año realizar la pregunta más trascendental que se le ocurra sobre los temas de ciencia de datos vistos, que sea respondible en esta maestría. Debe ser una pregunta conceptual que REALMENTE no sepa la respuesta y que considere que no le sería posible responder con facilidad (ej una consulta a Google o ChatGPT)

4 Herramientas, Conceptos, Operación y Buenas pácticas

4.1 UBA Preguntas de código, Google Cloud, Git, etc en clases presenciales

En las clases presenciales se verán temas conceptuales de Ciencia de Datos. En algunos casos se mostrará código para explicar o señalar algún concepto importante, en otras se hará una demostración de cómo correr una máquina virtual de Google Cloud. Otras veces si se detecta algún problema de código recurrente en los alumnos se explicará la solución conceptual en la clase presencial. Incluso en casos extremos de alumnos con una pobre computer literacy en donde el diálogo vía Zulip ya no sea suficiente (el alumno no percibe lo que aparece en su pantalla) se realizará una videoconferencia instructor-alumno vía Jitsi Meet, desde el mismo Zulip.
Sin embargo no se utilizará tiempo de la clase presencial para responder a preguntas puntuales sobre código, problemas puntuales de Google Cloud, Git & GitHub, ya sea a todo el curso o a algún alumno que se acerque con su laptop, ni minutos antes de la clase, ni después. Todas las preguntas técnicas deben canalizarse públicamente a través de Zulip, deben quedan registradas en para ambas comisiones, de forma que todos los alumnos se puedan enriquecer. En caso de ser necesario se coordinará una videoconferencia de soporte técnico.

Por supuesto, las clases presenciales están completamente abiertas a todas las preguntas de Ciencias de Datos y los profesores harán todo lo posible, hasta el límite de su conocimiento, por responder en algún momento de la clase presencial, o luego de una pertinente investigación.

4.2 UBA Preguntas de código, Google Cloud, Git, etc en Sesiones de Tutorias

En las sesiones de tutoria al igual que en las clases presenciales no se utilizará el tiempo para responder preguntas preguntas puntuales sobre código, problemas puntuales de Google Cloud, Git & GitHub. El soporte técnico siempre se brindará por Zulip y de ser necesario videollamadas.

4.3 Zulip

Zulip es el sistema nervioso de la asignatura.

Utilizaremos Zulip para

- Solicitar y brindar soporte técnico.
- Mantener discusiones en foros, asincrónicos fuera de las clases.
- Intercambiar mensajes, links, artículos, archivos entre alumnos entre sí, alumnos y profesores
- quizzes en la clase sincrónica y también en la tarea para el hogar asincrónica
- Cartelera de información de la asignatura
- resultados de Experimentos Colaborativos : 23 problemas
- Entregas de la materia

Zulip es una aplicación, open source, de chat y foros de discusión con videoconferencia integrada, que

permite organizar las conversaciones en *streams* y *topics* posibilitando mantener intercambio de ideas en paralelo, lo que es una gran ventaja si no se está online todo el tiempo. La existencia de hilos de conversación (streams)y tópicos permite una eficiente conversación no lineal y asincrónica.

Zulip es open source y está corriendo en un servidor propio, Slack no es open source. Zulip no está tan pulido y es menos intuitivo que Slack. Sin embargo Slack tiene la contra que revisar canales con mucha actividad se vuelve muy tedioso ya que no se dividen en tópicos.

Zulip permite enviar estos tipos de mensajes :

- privados a otro usuario o grupo de usuarios o a un stream privado
- públicos, a streams públicos, que actúan como salas de chat/foros de discusión

Todas las preguntas a profesores, sobre cualquier tema de la asignatura, deben ser siempre públicas. Es mandatoria esta transparencia. Escribir mensajes privados es caer en el oscurantismo de los emails, es dejar de compartir con el resto y evita que se pueda leer lo que otros están pensando.

Lo más probable es que usted acceda a Zulip desde su computadora y además tenga instalada la app en su smartphone (Android y iOS están soportados)

Zulip como aplicación permite esto https://zulip.com/features/ , una relativa "falencia" de Zulip es que no permite enviar mensajes de voz en forma nativa.

Un video que muestra como utilizar Zulip es https://www.youtube.com/watch?v=xWa56KdgYZM

Stream	**Utilidad**
z-CheckIn	CheckIn , será utilizado solamente para enviar el check in a la materia, la información es pública, y servirá de consulta constante a los profesores para personalizar la comunicación con cada alumno.
cartelera	alumnos no pueden enviar mensajes, profesores anuncian • recordatorios fechas importantes • commits del repositorio oficial • actualizaciones Libro de la Asignatura • bibliografía nueva • comunicaciones generales
Clase *n*	Cada clase tendrá su correspondiente stream, y estos dos tópicos estarán siempre presentes: • **antes** : de que tratará la clase y que debo traer hecho/leido • **despues**: resumen de lo que fue visto en clase, de las conclusiones
SoporteTecnico	Soporte técnico sobre R, Rstudio, scripts oficiales, librerías de R generales, no incluidos en streams específicos
data.table	Temas específicos y soporte técnico sobre data.table

Google Cloud	Temas específicos y soporte técnico de Google Cloud
Git & GitHub	Temas específicos y soporte técnico de Git y GitHub
Exp Colaborativos	Intercambio Experimentos Colaborativos
general	Diálogos generales.
memes	memes
off-topíc	estados de ánimo generales, todo lo que no valdría la pena ir a buscar a los threads oficiales
zero2hero	temas sobre From Zero to Hero
z-entregafinal	será utilizado para entregar la video presentación al Gerente de Ciencia de Datos

Los streams en fondo amarillo serán habilitados a su debido momento.

Si usted desea que un profesor preste atención a su mensaje, simplemente incluya `@profesores` en el texto de su mensaje.

Alumnos de promociones anteriores han manifestado la importancia que tiene elegir correctamente el thread y tópico de cada mensaje : poder encontrarlos en el futuro, tener lo de un mismo tema todo en un solo lugar.

4.3.1 Buenas prácticas para el uso de Zulip

Zulip es una herramienta asincrónica, sus compañeros y profesores pueden escribir en cualquier momento del dia o la noche, incluso durante el fin de semana.
En caso que usted no pueda acceder en forma diaria a Zulip, al ingresar se sentirá abrumado por la enorme cantidad de mensajes que han enviado sus compañeros y se planteará : "¿Qué es lo importante y que es lo que puedo obviar?

El stream `cartelera` es fundamental, ya que es ahi donde los profesores pasan unos pocos anuncios vitales.

Todo mensaje privado que reciba de compañeros, también será vital que los responda cuanto antes. Toda respuesta a un previo mensaje suyo también será importante que la vea cuanto antes. Si configuró bien Zulip, en estos dos casos usted recibirá un email para avisarle que tiene algo importante.

Los streams `clase` *n* y sus tópicos `antes` y `despues` tambien son vitales y debe leer lo antes posible todo mensaje que aparezca, ya que lo orientarán.

Es una maravillosa práctica que usted se cree un stream personal en Zulip con su nombre completo, que solamente usted podra ver y escribir en él, totalmente invisible a todos, incluso invisible a los profesores. En ese stream personal usted podrá escribir sus ideas, y también guardarse links (punteros) a otros mensajes que encontró interesantes.

Para todo el resto, le recomendamos esta estrategia que le ha resultado muy útil a alumnos de años previos:

1. Empezar a leer superficialmente todos los mensajes no leídos
2. Si el mensaje vale la pena, marcarlo con la estrella "Star this message Ctrl + s"

3. Luego, cuando disponga un momento de tranquilidad, ir a la carpeta de ★ `Starred Messages` y leer cada mensaje en detalle, quizas hasta preguntando algo a su autor. Una vez leido a conciencia el mensaje, si es muy importante guardar un link al mismo en su stream privado (el que tiene su nombre) y lo desmarca.
4. Con este método, ★ `Starred Messages` contiene los mensajes que temporalmente están pendientes de revision, y su stream privado contiene punteros a los mensajes que le interesaron.

4.3.2 Participaciones extraordinariamente significativas en Zulip

Muchos alumnos experimentan ansiedad sobre como participar en Zulip dado que no poseen conocimientos previos y suponen no tienen nada interesante para aportar.

Esta es la historia de Isidor I. Rabi premio Nobel de Física en 1944 por la invención de lo que luego permitiría la Resonancia Magnética.

Interviewer: `Why did you become a scientist, rather than a doctor or lawyer or businessman, like the other immigrant kids in your neighborhood?`

Rabi: `My mother made me a scientist without ever intending it.`
`Every other Jewish mother in Brooklyn would ask her child after school: 'So? Did you learn anything today?' But not my mother. She always asked me a different question.`
`'Izzy,' she would say, 'did you ask a good question today?'`
`That difference, asking good questions, made me become a scientist!"`

Son participaciones extraordinariamente significativas :

- Realizar una pregunta conceptual (no de soporte técnico).
- Responder una pregunta técnica a un compañero.
- Recomendar bibliografía *junto con un comentario por haber sido leida peviamente*.
- Compartir resultados de análisis exploratorio de datos.
- Compartir un problema que se tuvo y la forma en que se solucionó.
- Compartir tips sobre como operar eficientemente alguna aplicación.

4.3.3 Participaciones significativas en Zulip

Son participaciones significativas en Zulip:

- Una pregunta técnica que aún no fue realizada por un compañero

La cátedra prefiera que usted realice preguntas ténicas por Zulip en lugar del grupo privado de whatsapp para así poder entender los temas que no están quedando claros y reforzarlos ya sea por Zulip mismo o en la clase.
Es preferible curar a ese paciente aún con vida, antes que una vez finalizada la materia realizar una autopsia para entender que salió mal y salvar vidas futuras.

4.3.4 Mensajes Privados a los profesores Permitidos

Todas las preguntas a profesores, sobre cualquier tema de la asignatura, deben ser siempre públicas.

La heterogeneidad de alumnos en las maestrías de ciencias de datos genera que por un lado nos encontramos con alumnos que ya saben programar, se encuentran trabajando en ciencia de datos y realizan preguntas avanzadas en clase, mientras que otros recién están aprendiendo lo básico.
Por lo general, varios alumnos se sienten tentados a preguntar en forma privada al profesor, manifiestan tener miedo que su pregunta sea elemental, o incluso mal formulada, que pueda ser mal vista por el resto. Se sienten incómodos con dicha exposición. Le doy una maravillosa noticia, el 65% de los alumnos está en su misma situación, con lo que al hacer en forma pública la pregunta que considera elemental, dará una alentadora señal al resto y se producirá la propiedad emergente que muchos más se animen a preguntar, y tal cual lo expresa Eric Mazur será muy posible que obtenga una clara respuesta de un compañero que acaba de aprender el tema hace muy poco.

Estos son ejemplos de mensajes privados dirigidos a los profesores, que por no hablar de la asignatura, y ser sobre temas privados, si están permitidos.

"Me surgió una posibilidad laboral en Madrid y la acepté, por lo que me voy a estar yendo en las próximas semanas y estoy haciendo gestiones a destajo. Como te podrás imaginar voy a tener que dejar el posgrado, aunque pienso empezar otro allá. Y en este punto, si sabés y tenés ganas de pasarme info, me vendría muy bien recomendaciones de buenos programas de maestría en ciencia de datos."

"Más adelante... si es posible y no es molestia, quisiera consultarte si podrías orientarme en encontrar una aplicación (PROYECTO DE TESIS) en la Industria Petroquímica / Generación de Energía....que es donde me desempeño actualmente.
Por supuesto que encontrar la aplicación es mi tarea, pero quizás algún exalumno hizo o está haciendo algo dentro del campo...o hay algún paper que se me esté escapando... . Cualquier dato es bienvenido. "

5 Tutorías

Asistir a las clases presenciales es optativo; asistir a las sesiones de tutoría mandatorio.

5.1 Objetivo

La asignatura intenta replicar un proyecto profesional real mediante la modalidad de Authentic Learning, en donde debe construirse iterativamente un excelente modelo predictivo y explicar resultados mediante vídeos a dos actores de la empresa.
A fin de garantizar el éxito del proyecto cada alumn@ participará periódicamente (especialmente previo y posterior a entregas) de sesiones de tutorías, en donde junto a otros dos alum@s y un@ tutor@ recibirá retroalimentación constructiva personalizada sobre el avance de su proyecto incentivando mediante el análisis crítico la mejora.

5.2 Tuplas de tutoría

La cátedra en las primeras semanas de cursada definirá *tuplas de tutoría* dadas por `<tutor, estudiante`$_1$`, estudiante`$_2$`, estudiante`$_3$`>` donde los estudiantes tendrán un nivel equivalente y la tupla presenta altas posibilidades de sinergias tutor-estudiante y estudiante-estudiante incluyendo la compatibilidad de agendas.
Se intentará mantener las tuplas intactas durante toda la asignatura. Las tuplas pueden llegar a estar formadas por alumnos pertenecientes a distintas comisiones si la cátedra así lo considera.
Los estudiantes no participan en el armado de las *tuplas de tutoría*.
Estas tuplas de tutoría no necesariamente guardan relación alguna con los grupos de estudio de l@s estudiantes ni tampoco con los grupos que forman para las competencias de la asignatura, los cuales se suelen forman por afinidad y los estudiantes poseen completa libertad en su armado. La riqueza radica en que los grupos de estudio integren la diversidad de perspectivas adquiridas en las distintas tutorías.

Los tuplas de tutoría más avanzadas exploran temas muy distintos a las tuplas que están lidiando con conceptos básicos, generando soluciones y enfoques diferenciados.

En caso que alumnos abandonen la materia, se reorganizarán algunas tuplas.

5.3 Agenda de sesiones de tutorías

Cada tutor negociará con los estudiantes la fecha y hora de la siguiente tutoría especificando claramente por escrito en el correspondiente canal dde Zulip los temas que deben ser trabajados previamente por los estudiantes para ser debatidos durante la sesión de tutoría.
Las sesiones de tutorías serán (salvo excepciones) en un horario distinto al de las clases sincrónicas. Sin embargo la cátedra deja abierta la posibilidad a que cierto dia puntual coincidente con una clase sincrónica sea reemplazada por una maratón de tutorías.

5.4 Trabajo previo

Los estudiantes siempre deben asistir a la sesión de tutoría habiendo realizado el trabajo previo acordado con su tutor, generalmente experimentos para mejorar el modelo predictivo.

5.5 Sesión de tutoría

La sesión de tutoría consiste de una videollamada de 55 minutos de duración en la que se produce un diálogo entre los cuatro integrantes de la *tupla de tutoría* fomentando el pensamiento crítico, abordando los problemas desde múltiples perspectivas analizando soluciones, identificando posibles errores y refinando el razonamiento mediante preguntas desafiantes y retroalimentación constructiva.
El tutor suele hablar el 30% del tiempo generalmente formulando preguntas y los tres estudiantes en forma equitativa el 70% restante.

El tutor abre la sesión preguntando a los estudiantes sobre avances y problemas encontrados en la etapa del proyecto de modelado en generar y también sobre otros micro proyectos agendados para esa sesión de tutoría.

Los estudiantes explican lo realizado, el racional detrás de las decisiones tomadas a lo que el tutor indaga en profundidad, solicita detalles, cuestiona todas las decisiones, detecta razonamientos incorrectos y los marca constructivamente a los estudiantes, solicita al estudiante que lleva a la palabra (y a los otros dos) soluciones alternativas y su análisis crítico. El tutor indaga constantemente el "por qué".

En casos puntuales el tutor clarifica temas conceptuales de las clases sincrónicas sin embargo el tutor jamas utiliza el tiempo de la tutoría para dictar una "mini clase" acaparando el 50% del tiempo.

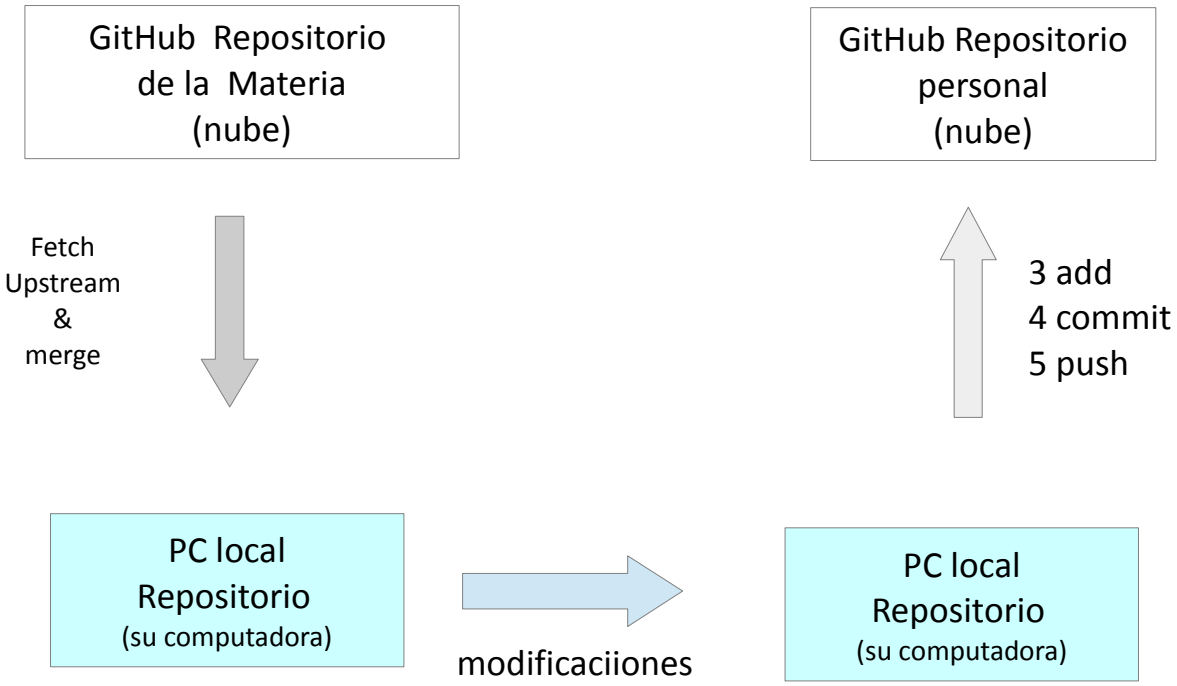
El tutor no hace "spoonfeeding" en la sesión de tutoría, jamás brinda instantáneamente la receta que resuelve el problema o mejora el modelo. Ante una decisión a tomar por l@s estudiantes el tutor debe enseñar a abordar criticamente el problema y proveer a l@s estudiantes las herramientas para que ellos resuelvan.

El estudiante jamás participa de la tutoría sin haber preparado la tarea asignada, ya que la tutoría se basa en darle retroalimentación constructiva sobre lo hecho y producir nuevos avances.
El estudiante no espera una respuesta directa a su pregunta, sabe que está ahí para razonar él mismo la respuesta. El estudiante dialoga, cuestiona lo que el tutor y los otros estudiantes dicen, llega con ciertas ideas a la sesión y las transforma en superadoras durante la sesión.

La filosofía de las tutorías es *"Not what to think, but how to think."*

6 Git y GitHub

6.1.1 conceptos y operación



o desde la línea de comando de la PC local

```
git checkout main
git pull

git fetch upstream
git checkout main
git merge  -Xtheirs  upstream/main   -m "Z manda"

git checkout main
git add .
git commit -m "otro commit"
git push
```

6.2 Librería data.table del lenguaje R

En el lenguaje R tradicional se utiliza el objeto `dataframe` que posee severas deficiencias en cuanto a performance y rebuscada complicada. En esta asignatura utilizamos la librería `data.table` que es ampliamente superadora y que permite manejar grandes volúmenes de datos, tiene una sintaxis más simple PERO muy distinta a la de dataframes, por lo que es necesario aprenderla.
Leer los siguientes artículos

- https://towardsdatascience.com/data-table-rs-best-data-object-c95b7d5f0104
- https://towardsdatascience.com/blazing-fast-data-wrangling-with-r-data-table-de5045cc4b4d
- introduction to data table https://cran.r-project.org/web/packages/data.table/vignettes/datatable-intro.html
- data.table cheat sheet https://www.beoptimized.be/pdf/R_Data_Transformation.pdf

7 Niveles de complejidad

A lo largo de los años se han observado escalones cognitivos que para cada uno de los temas l@s estudiantes deben escalar en función de sus conocimientos previos, sesgos cognitivos y dedicación a la asignatura.

7.1 Etapa Preprocesamiento de Datos

7.1.1 Armado del Target

Nivel Uno, utiliza Positivos = {“BAJA+2”} Negativos = {“BAJA+1”, “CONTINUA”} y para cortar utiliza el umbral de probabilidad PROB(“BAJA+2”) >= 0.025 (1/40)

7.1.2 Dimensionalidad del dataset

7.1.3 Tratamiento Valores faltantes

7.1.4 Calidad de Datos

7.1.5 Data Drifting

7.1.6 Feature Engineering intra mes

7.1.7 Feature Engineering histórico

7.1.8 Aceleración Procesamiento

7.2 Etapa Modelado

7.2.1 Clase Target

7.2.2 Estrategia Entrenamiento

7.2.3 Algoritmo

7.2.4 Optimizacion de Hiperparámetros

7.3 Etapa Puesta en Produccion

8 Experimentos Colaborativos

El gran objetivo es encontrar cuál es la mejor configuración de las etapas del workflow que genere la mejor predicción.
Para ello se parte de una buena solución, la configuración workflow-inicial y basado en ella mediante la experimentación se prueban alternativas a la configuración inicial, o incluso, para el caso de alumnos avanzados, se agrega nueva funcionalidad a los scripts del workflow.

Aclaración importante : el objetivo de estos experimentos es el capitalismo salvaje, lográr ganar más dinero que el workflow-inicial. Decididamente NO nos son experimentos académicos por el amor al conocimiento abstracto.

Cada problema es abordado por dos grupos experimentadores antagónicos, el Grupo A y el Grupo B, que utilizando diseños experimentales distintos intentan responder la Hipótesis Experimental. Se puede leer lo siguiente para entender esta usual práctica de la reproducción de un experimento en el mundo científico https://www.ncbi.nlm.nih.gov/pmc/articles/PMC5778115/

Se ha observado que la etapa inicial de elección de un problema despierta en ocasiones ciertas batallas y malos entendidos entre los alumnos, para lo cual se han diseñado un conjunto de reglas simples orientadas a suavizar las fricciones.

Es el objetivo de la cátedra que los experimentos realizados sean auténticamente útiles para encontrar el mejor modelo predictivo. Lograr lo anterior demanda experimentar en el entorno de una buena configuración general de parámetros la que es “computacionalmente pesada”.
Por la naturaleza de la ciencia de datos se cumple generalmente que utilizando algoritmos de Gradient Boosting of Decision Trees, entrenar en mayor cantidad de datos (mas historia y más columnas) produce mejores modelos predictivos.

Si se entrena en datasets pequeños se llega a parámetros óptimos de las etapas del workflow que luego no se corresponden con los que se encuentran si el entrenamiento se hace en un dataset grande de varios meses.
Las corridas con grandes volúmenes de datos son naturalmente más lentas, más propensas a fallas de una máquina virtual, requieren de más control, y por lo general intentan ser evitadas por los alumnos.

Es tarea de la cátedra enseñarle a buscar y encontrar el procedimiento que produce los mejores resultados y que usted sea capaz de ponderar el costo beneficio de la experimentación.

No intente buscar atajos suboptimos en la experimentación !

8.1 Documento Colaborativo Google Slides

En el documento colaborativo de Google Slides se encuentran las siguientes secciones:

- Indice
- Plantilla de Problema, en donde hay un slide para cada uno de los capítulos
    1. Portada
    2. Hipótesis Experimental
    3. Bibliografía
    4. Sesgos Cognitivos
    5. Diseño Experimental
    6. Limitaciones
    7. Resultados
    8. Discusión de los resultados
    9. Conclusiones
    10. Recomendación Concreta
    11. Futuros problemas y experimentos
    12. Anexo
- Ejemplo completo de un Problema resuelto por un grupo A y la contraparte grupo B
- 14 Potenciales Problemas a resolver, con su portada, hipótesis experimental y en algunos casos algo de bibliografía.

Los capítulos de la Plantilla del Problema y su estricto orden deben respetarse siempre; por supuesto algunos de los capítulos podrán demandar más de un slide.

Será en este mismo documento colaborativo donde los alumnos escriban sus presentaciones.
El Grupo A tendrá su presentación completa con todos los capítulos y a continuación vendrá la presentación del Grupo B la que también incluirá todos los capítulos, incluirá su propia Portada e Hipótesis Experimental que deberán ser idénticas a las del Grupo A

Lo más razonable es que usted elija uno de los Potenciales Problemas que ya aparecen en el documento, los que superan la cantidad de grupos posibles de esta cohorte. Si usted quisiera resolver un problema que no está planteado en el documento, deberá proponérselo a los profesores y éstos darle su autorización en función de los temas que fueron elegidos por el resto de los alumnos, que los problemas más interesantes tengan grupos asignados que los resuelvan, que usted tenga el know how suficiente en este momento para enfrentar el problema, etc

8.2 Problemas disponibles y alumnos avanzados

En el documento colaborativo de Google Slides la cátedra ha propuesto una serie de problemas cuyos experimentos son muy relevantes para la generación de un modelo que auemnte la ganancia y factibles de realizar en el tiempo disponible.
Si usted es una alumno avanzado con conocimientos previos de Ciencia de Datos o de Estadística Clásica, se lo autoriza a que :

- Proponga a los profesores un nuevo Problema, junto con su diseño experimental
- Convenza a uno o dos alumnos más, no necesariamente estos avanzados, para poder conformar los grupos antagónicos A y B

8.3 Configuración de los grupos

A continuación las únicas dos configuraciones posibles en cuanto a la cantidad de integrantes de los grupos para un problema:

Configuraciones Válidas # Integrantes por equipos		
Configuración	Grupo A	Grupo B
Solitaria	1	1
Asimétrica	2	1

Por favor notar que siempre deben existir los dos grupos antagónicos para un Problema, los que realizan diseños experimentales distintos.
No pueden trabajar cuatro personas en un mismo problema, es un desperdicio de materia gris.

8.4 Forma de pre registración

Simplemente anote su nombre en la portada del problema que es de su interés.
Podrá anotar su nombre en un único problema. Siempre podrá cambiarlo por otro problema en la medida que se cumpla el proceso que sigue a continuación.

8.5 Negociación de Problemas : vacancia

Se cumple lo siguiente:

- Cada problema requiere como mínimo dos personas, una que integre el Equipo A y otra que integre el Equipo B.
- Hay una oferta de Potenciales Problemas mayor a la cantidad de equipos posibles

Las condiciones anteriores producen por lo general la situación de personas que anotan su nombre en uno de los Potenciales Problemas y ese problema no le interesa a nadie más, pasan los días y nadie más anota su nombre en esa portada.

Esta persona deberá :

- convencer a otras que se pasen a su problema, al menos una persona más
- o abandonar ese problema y unirse a algún otro problema/grupo que esté en etapa de formación.

8.6 Negociación de Problemas : sobreoferta

Esta es la situación que produce mas fricciones y sensación de injusticia entre los alumnos.

Se sumple lo siguiente:

- A pesar de haber sobreabundancia de Potenciales Problemas, hay algunos muy populares en el imaginario de los alumnos que son pretendidos por más de tres alumnos.
- Hay algunos alumnos que ingresan al Google Slides varios dias después del lanzamiento de la registración y desean unirse a un problema con sobreoferta de alumnos.

Negocie sin intentar sacar ventajas solo por haber llegado antes.

8.7 Asignación Grupo A vs Grupo B

El grupo A posee cierta ventaja ya que es quien primero establece el diseño experimental, y una vez que este fue aprobado por los profesores deberá el Grupo B proponer su diseño experimental, mandatoriamente distinto, el que también deberá ser aprobado por los profesores, deberán garantizar que los diseños experimentales sean lo suficientemente disjuntos.

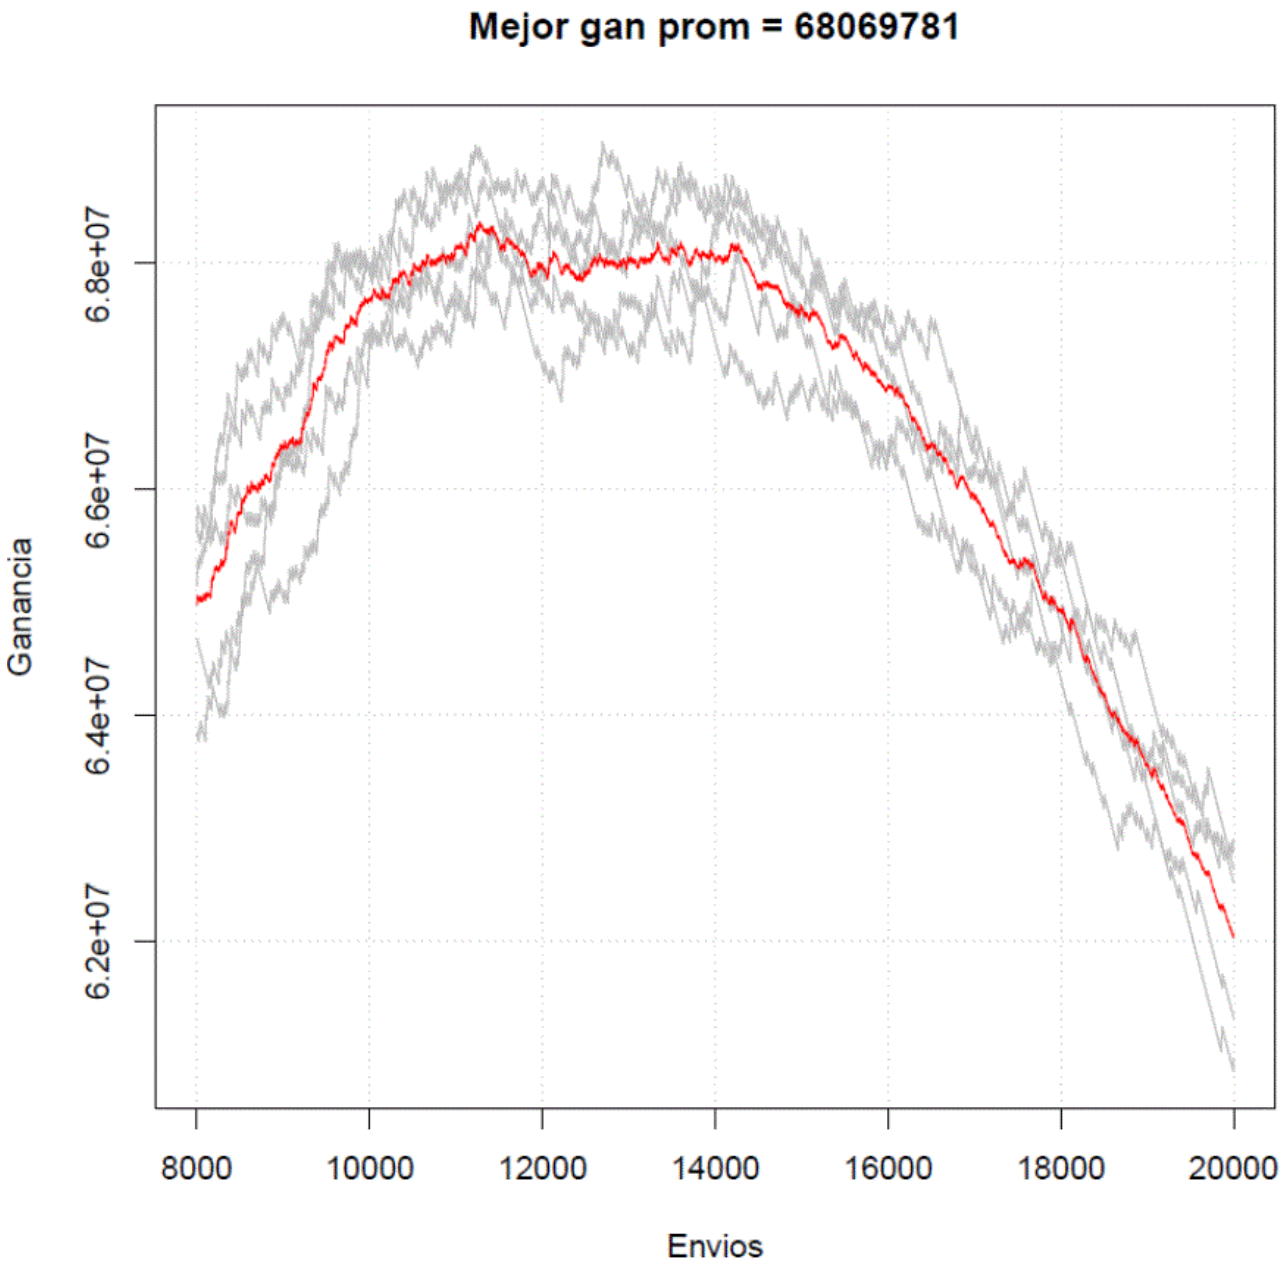
Dicha mínima ventaja a favor del Grupo A tiene el potencial de generar algun tipo de conflicto. Se sugiere en este caso tirar una moneda al aire.

8.8 Antagonismo de los grupos

Para un problema dado, el Grupo A y el B son antagónicos. Ellos intentan llegar a resultados distintos. Solo se comunican al principio, cuando el Grupo A establece su diseño experimental y el B está obligado a hacer uno completamente distinto. A partir de allí, nunca más interactuan, evitan por todos los medios de contaminar sus mentes con potenciales ideas equivocadas del otro grupo.

8.9 Perídos de análisis de los grupos

Los grupos A y B analizarán distintos períodos con el objetivo de determinar si lo que mejor funciona lo hace lamentablemente para un solo período o si por el contrario es una propiedad que generaliza.



8.10 Aprobación de Diseños Experimentales

El procedimiento a seguir es el siguiente

1. Al Grupo A deberá cuanto antes escribir su diseño experimental en el Google Slides colaborativo, y solicitar rápidamente su revisión a los profesores, por medio de Zulip. En esta etapa podrá haber una brevísima conference con el profesor.
2. Luego de un ida y vuelta, a la mayor brevedad el profesor, por Zulip, aprueba el diseño experimental del Grupo A. En ese momento el Grupo A ya puede comenzar la experimentación.
3. El Grupo B, viendo ese diseño experimental aprobado, construye un diseño experimental alternativo, y solicita la aprobación del profesor.
4. Luego de un ida y vuelta, el profesor, por Zulip, aprueba el diseño experimental del Grupo B, y éste puede comenzar la experimentacion.

8.11 Ceteris Paribus

Cada Potencial Problema hace referencia unicamente a una parte de un script.
Los grupos que intenten resolver una Hipótesis Experimental deberán hacer modificaciones a los parámetros del correspondiente script, o en caso de tener el conocimiento suficiente al código del script, pero deberán mantener sin modificación el resto de los scripts que no son objeto de su experimentación, excepto :

- las semillas generales de todos los scripts que siempre deben ser cambiadas a las propias.
- Las pruebas que se realicen en otros períodos “future”, donde se elije un mes para el que se conoce la clase y se pueden dibujar las curvas

Concretamente, en los scripts de workflow-inicial se entrena en 18 meses de historia ya que esto produce buenas ganancias. Excepto que su Problema sea el de probar la cantidad óptima de meses donde entrenar, usted deberá correr el worflow respetando esos 18 meses y no podrá tomar ningun atajo de utilizar menos meses para que sus procesos corran m+as rápido.
Una vez que haga las corridas esperadas con esos 18 meses, podrá agregar a los experimentos, como algo adicional, alguna corrida en menos meses.

8.12 Capítulo Conclusiones

El capítulo de las conclusiones, en alguna parte se debe dar una receta bien concreta : ¿Cómo se deben setear los parámetros de esa etapa del Workflow? Incluso para el caso que los experimentos no sean concluyentes se debe dar una clara receta.
Por supuesto, quienes lean el experimento simplemente lo tomarán como un punto de partida a sus propios “últimos experimentos”.

8.13 Video Presentaciones Ejecutivas

Los links a las video presentaciones de los distintos problemas deberán disponiblizarse antes de la fecha

indicada en el Cronograma de la Asignatura, y se harán directamente a partir del documento colaborativo de Google Slides.

9 ¿Cómo seguir?

9.1 Mantenerse actualizado

¿En que sitios es posible mantenerse actualizado luego de finalizada la asignatura ?

- https://machinelearningmastery.com/
- https://www.kdnuggets.com/
- https://www.analyticsvidhya.com/
- https://neptune.ai/blog
- https://www.fast.ai/#category=technical
- https://openai.com/blog
- https://www.deepmind.com/blog
- https://blog.ml.cmu.edu/
- https://news.mit.edu/topic/machine-learning

9.2 Datasets Públicos

¿Dónde encontrar datasets públicos para una Tesis de Maestría o practicar ?

- https://cloud.google.com/datasets
- https://github.com/awesomedata/awesome-public-datasets
- https://www.kaggle.com/datasets
- https://www.datos.gob.ar/dataset
- https://data.buenosaires.gob.ar/dataset/
- https://data.gov/
- https://careerfoundry.com/en/blog/data-analytics/where-to-find-free-datasets/
- https://medium.com/analytics-vidhya/top-100-open-source-datasets-for-data-science-cd5a8d67cc3d
- https://www.v7labs.com/open-datasets
- https://azure.microsoft.com/en-us/products/open-datasets/
- https://registry.opendata.aws/

10 Empiricismo en la Ciencia de Datos

En el Machine Learning muchos algoritmos son encontrados por prueba y error, al inicio se los prueba en decenas de datasets, se divulgan, los usa la comunidad, ganan competencias Kaggle, pasan a ser usados por practicantes en innumerables situaciones, pero carecen de demostraciones matemáticas sobre su robustez- Recién luego de varios años, o más de una década se demuestra la razón por la que funcionan, los efectos que se observan y las razones de su poder (por ejemplo que converjan o que el overfitting esté controlado).

Esta situación colisiona violentamente con quienes provienen de la estadística clásica.

10.1.1 Bibliografía Introductoria

- https://www.kdnuggets.com/2015/07/deep-learning-triumph-empiricism-over-theoretical-mathematical-guarantees.html
- https://royalsocietypublishing.org/doi/pdf/10.1098/rsta.2016.0153
- https://journals.plos.org/plosmedicine/article?id=10.1371/journal.pmed.0020124
- https://ris.utwente.nl/ws/files/177935074/Boon_2020_BioTechnoPractic_How_scientists_are_brought_back_into_science_preprint_May_9_2019.pdf
- https://hdsr.mitpress.mit.edu/pub/l39rpgyc/release/1
- https://www.youtube.com/watch?v=oONHlua2gBY
- https://royalsocietypublishing.org/doi/10.1098/rsta.2018.0145

Arquetípico ejemplo de empiricismo, acontecido en la medicina

- https://www.redalyc.org/journal/920/92044744013/html/ leer la sección **Anexo Semmelweis y la fiebre puerperal** (está después de la bibliografía)

11 Las dos culturas en el modelado predictivo

- El paper original de Leo Breiman Statistical Modeling, The Two Cultures
  http://www2.math.uu.se/~thulin/mm/breiman.pdf

https://towardsdatascience.com/thoughts-on-the-two-cultures-of-statistical-modeling-72d75a9e06c2

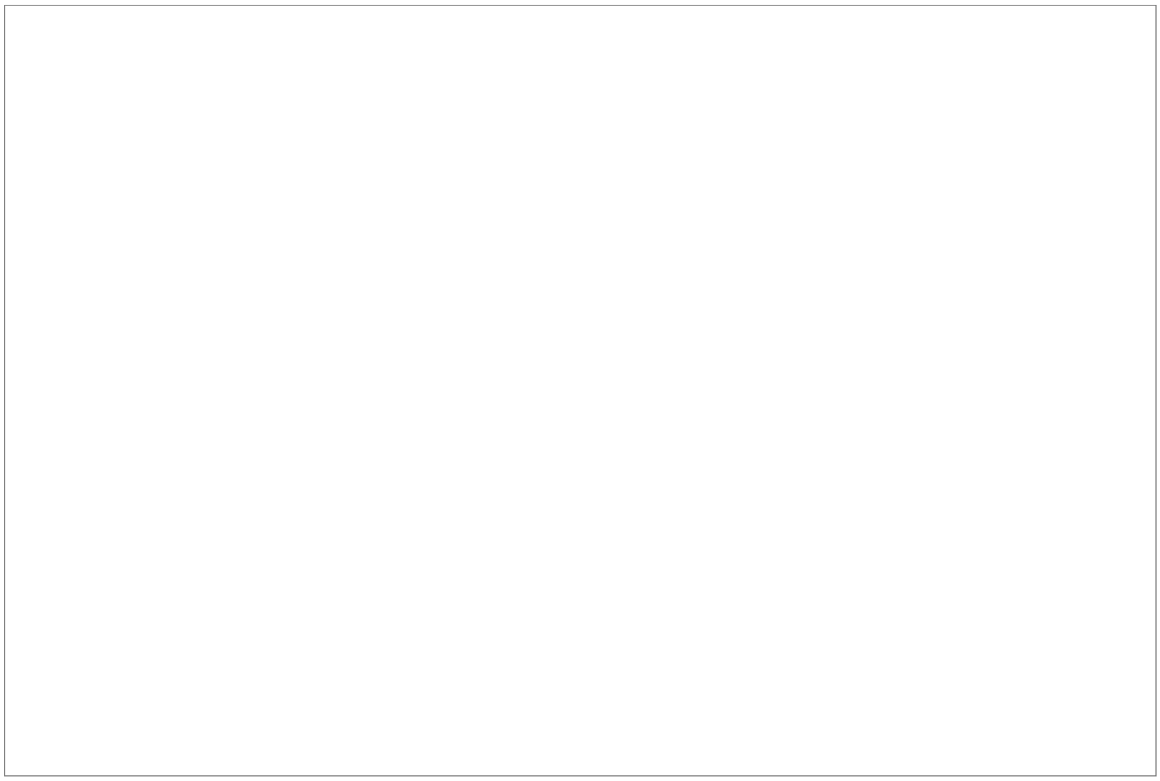
12 Estimando la Ganancia de un modelo predictivo

12.1 Bibliografía Introductoria

Bibliografía

- https://machinelearningmastery.com/statistical-significance-tests-for-comparing-machine-learning-algorithms/
- https://citeseerx.ist.psu.edu/viewdoc/download?doi=10.1.1.183.534&rep=rep1&type=pdf

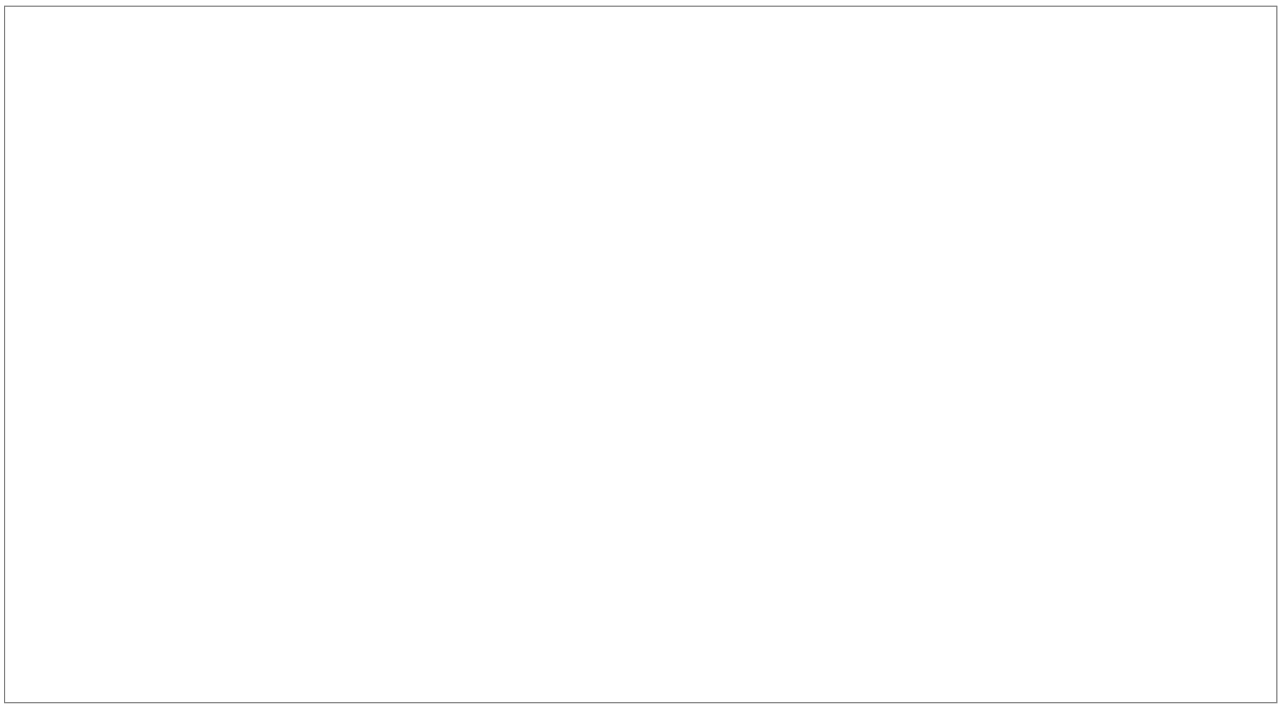
12.2 Sesgo Varianza en la estadística clásica



12.2.1 Bibliografía Inicial

- https://machinelearningmastery.com/gentle-introduction-to-the-bias-variance-trade-off-in-machine-learning/
- http://scott.fortmann-roe.com/docs/BiasVariance.html (15 minutos)

12.3 Sesgo Varianza en el moderno Machine Learning



12.3.1 Bibliografía Inicial

- https://medium.com/mlearning-ai/double-descent-8f92dfdc442f
- https://arxiv.org/pdf/1812.11118.pdf

13 Análisis exploratorio de datos

13.1 Consistencia longitudinal de los atributos

13.2 Drifting de atributos

En el período (mes) donde debo aplicar el modelo para hacer la predicción final, ¿existen variables con una distribución distinta a los períodos anteriores?

- https://towardsdatascience.com/data-drift-part-1-types-of-data-drift-16b3eb175006
- https://towardsdatascience.com/data-drift-part-2-how-to-detect-data-drift-1f8bfa1a893e
- https://towardsdatascience.com/machine-learning-in-production-why-you-should-care-about-data-and-concept-drift-d96d0bc907fb
- https://medium.com/data-from-the-trenches/a-primer-on-data-drift-18789ef252a6

- https://arxiv.org/pdf/2004.05785.pdf
- https://wires.onlinelibrary.wiley.com/doi/epdf/10.1002/widm.1381

13.3 Tratamiento de variables "rotas"

¿Qué funciona mejor con una variable "rota" para un mes? ¿ Imputar su valor interpolando, o asignarle nulo? sí, ha leído bien, estamos proponiendo asignar NA a una variable !

13.4 Tratamiento de nulos

¿Debo tratar a los nulos de alguna forma en especial?

¿Es razonable eliminar un registro donde algún campo importante sea nulo?

¿Qué funciona mejor, imputar nulos con alguna metodología o permitir que XGBoost/LightGBM trabajen con ellos?

13.5 Tratamiento de outliers

¿Debo tratar a los outliers de alguna forma en especial?

¿Qué funciona mejor, tratar los outliers con alguna metodología o permitir que XGBoost/LightGBM trabajen con ellos?

¿Qué pasa con los outliers en el bining que realiza LightGBM?

14 Algoritmo: Árbol de Decisión

14.1 Bibliografía Inicial

Capítulo 9.2 de https://hastie.su.domains/Papers/ESLII.pdf

Optimización de hiperparámetros https://bradleyboehmke.github.io/HOML/DT.html

Explicacion sobre rpart https://www.learnbymarketing.com/tutorials/rpart-decision-trees-in-r/

14.2 El hiperparámetro cp en la librería rpart

En esta materia "un experimento no se le niega a nadie" , con lo cual independientemente de lo que digan papers, libros, otras materias, profesores con gran cantidad de tiras en su uniforme, towardsdatascience e incluso el infame Medium, haremos el experimento, y que una optimización de hiperparámetros diga si el hiperparámetro cp óptimo es positivo o negativo.
Luego, ante la evidencia experimental, si un **cp** negativo es el óptimo, buscaremos una explicación, aquellos que tengan ganas y tiempo harán nuevos experimentos.
Seamos fieles a "The problem is that people are educated just enough to believe what they have been taught, and not educated enough to **question anything from what they have been taught**" y maravillarnos ante nuestra propia ignorancia y tendencia a ponernos cómodos techos.

"I am **tormented** with an everlasting itch for things remote. I love to sail **forbidden** seas. " Moby Dick

15 Comparación de Modelos Predictivos

15.1 Bibliografía Inicial

Cross Validation https://machinelearningmastery.com/k-fold-cross-validation/

Receta https://machinelearningmastery.com/statistical-significance-tests-for-comparing-machine-learning-algorithms/

Paper https://citeseerx.ist.psu.edu/viewdoc/download?doi=10.1.1.183.534&rep=rep1&type=pdf

16 Optimización de Hiperparámetros

16.1 Bibliografía Introductoria

16.2 Grid Search

16.3 Bayesian Optimization

- https://towardsdatascience.com/bayesian-optimization-concept-explained-in-layman-terms-1d2bcdeaf12f
- https://towardsdatascience.com/the-beauty-of-bayesian-optimization-explained-in-simple-terms-81f3ee13b10f
- Taking the Human out of the Loop (para quienes quieran leer en profundidad en algún momento tranquilo de la vida)

17 MLOPS

17.1 Bibliografía Inicial

- https://towardsdatascience.com/a-gentle-introduction-to-mlops-7d64a3e890ff

18 Curva ROC

18.1 Bibliografía

- Ling, C. X., Huang, J., & Zhang, H. (2003, August). AUC: a statistically consistent and more discriminating measure than accuracy. In Ijcai (Vol. 3, pp. 519-524). https://www.ijcai.org/Proceedings/03/Papers/077.pdf

18.2 Curva ROC de un split en un árbol de decisión

18.3 Curva ROC de un modelo predictivo

18.4 Relación de la Curva ROC con la función de ganancia

19 Controlando el False Discovery Rate

19.1 Bibliografía Introductoria

- https://journals.plos.org/plosmedicine/article?id=10.1371/journal.pmed.0020124
- https://www.youtube.com/watch?v=6ZxIzVjV1DE (subtitulos en ingles activables)

20 Feature Engineering

20.1 Bibliografía Introductoria

- https://www.youtube.com/watch?v=X4pWmkxEikM
- https://www.youtube.com/watch?v=06-AZXmwHjo video Andrew Ng

20.2 Cambiando la clase

La clase a predecir es POS = { BAJA+2 } , NEG = { BAJA+1, CONTINUA }

La forma natural de predecir es con POS = { BAJA+2 } , sin embargo ¿Es esa la mejor forma, o me convendría entrenar con otra clase?

20.3 Variables Manuales

Artículos donde resolvieron un problema similar

- https://www.researchgate.net/profile/Xingsen-Li/publication/224759968_The_Analysis_on_the_Customers_Churn_of_Charge_Email_Based_on_Data_Mining_Take_One_Internet_Company_for_Example/links/5891e87a92851cda256a0358/The-Analysis-on-the-Customers-Churn-of-Charge-Email-Based-on-Data-Mining-Take-One-Internet-Company-for-Example.pdf

Tesis de maestría donde se solucionó un problema parecido.

- https://core.ac.uk/download/pdf/83461632.pdf
- http://research.sabanciuniv.edu/39116/1/AneelaTanveer_10236886.pdf
- https://arrow.tudublin.ie/cgi/viewcontent.cgi?article=1218&context=scschcomdis

20.4 Transformaciones tradicionales

¿Qué efectos tienen en un árbol de decisión y algoritmos derivados, transformaciones del tipo: ?

- transformación lineal x' = ax + b
- x' = log(x)
- normalización

20.5 Variables históricas

20.6 Lags y delta lags

20.7 Tendencias

20.8 Medias móviles

20.9 Ajuste por Inflación

20.10 Variables hojas de un Random Forest

20.11 Reducción de la dimensionalidad para acelerar

21 Ensembles de Modelos

21.1 Bibliografía Introductoria

- BBC - The Code - The Wisdom of the Crowd https://www.youtube.com/watch?v=iOucwX7Z1HU (5 minutos)
- https://www.all-about-psychology.com/the-wisdom-of-crowds.html (10 minutos)
- https://machinelearningmastery.com/what-is-ensemble-learning/ (10 minutos)

22 Algoritmo: Random Forest

22.1 Bibliografía Introductoria

- https://www.youtube.com/watch?v=J4Wdy0Wc_xQ
-

23 Algoritmo: Gradient Boosting of Decision Trees

23.1 Bibliografía Introductoria

23.2 XGBoost

23.2.1 Bibliografía XGBoost

Inicial

- https://towardsdatascience.com/xgboost-regression-explain-it-to-me-like-im-10-2cf324b0bbdb
- https://towardsdatascience.com/https-medium-com-vishalmorde-xgboost-algorithm-long-she-may-rein-edd9f99be63d
- https://machinelearningmastery.com/gentle-introduction-xgboost-applied-machine-learning/

Avanzada

- paper original de XGBoost https://dl.acm.org/doi/pdf/10.1145/2939672.2939785
-

23.3 Optimización hiperparámetros XGBoost

- https://www.hackerearth.com/practice/machine-learning/machine-learning-algorithms/beginners-tutorial-on-xgboost-parameter-tuning-r/tutorial/
- Narrowing the Search: Which Hyperparameters Really Matter?

23.4 Bibliografía LightGBM

Avanzada

- Paper original de LightGBM https://papers.nips.cc/paper/2017/file/6449f44a102fde848669bdd9eb6b76fa-Paper.pdf
-

23.5 Optimización hiperparámetros LightGBM

- https://lightgbm.readthedocs.io/en/latest/Parameters-Tuning.html
- http://devdoc.net/bigdata/LightGBM-doc-2.2.2/Parameters-Tuning.html
- https://neptune.ai/blog/lightgbm-parameters-guide

24 Estrategia de Entrenamiento

24.1 Determinación de los mejores períodos para entrenar

24.2 Acelerando el entrenamiento : evitando el cross validation

24.3 Acelerando el entrenamiento : Undersampling de la clase mayoritaria

25 Importancia de Variables

25.1 Bibliografía Introductoria

25.2 Valores Shapley

- ttps://www.youtube.com/watch?v=ngOBhhINWb8
- https://www.youtube.com/watch?v=B-c8tIgchu0

26 Ensembles de Modelos Segunda Parte

Bibliografía de Model Stacking

- https://www.youtube.com/watch?v=DCrcoh7cMHU
- https://www.youtube.com/watch?v=8T2emza6g80
- https://www.kdnuggets.com/2017/02/stacking-models-imropved-predictions.html
- https://medium.com/ml-research-lab/stacking-ensemble-meta-algorithms-for-improve-predictions-f4b4cf3b9237
- https://citeseerx.ist.psu.edu/viewdoc/download?doi=10.1.1.56.1533&rep=rep1&type=pdf el paper original del año 1992

26.1 Semilleríos

26.2 Hibridación de Semilleríos

27 Acelerando el procesamiento

27.1 Bibliografía Inicial

- https://medium.com/hmif-itb/overfitting-the-leaderboard-da25172ac62e
- https://www.kaggle.com/general/54610
- http://gregpark.io/blog/Kaggle-Psychopathy-Postmortem/

27.2 El problema de la calibración en Gradient Boosting

27.3 Otra forma de cortar

28 Clustering jerárquico basado en la distancia de Random Forest

Un modelo de Random Forest es un ensemble de árboles de decisión. Ese ensemble puede servirnos para definir una distancia entre registros del dataset. Esta distancia que decididamente no es la euclídea, es insensible a los outliers, a los nulos y a las diferencias de escala de las variables; no hace falta normalizar los atributos del dataset.

Utilizando esa distancia podemos realizar una partición por el método de clusters jerárquicos.

29 Storytelling

29.1 Historia

Al finalizar su primer año del posgrado en ciencia de datos usted ingresa como data scientist en la compañía al sector de Business Intelligence.

El sector está liderado por la gerenta Michelina Porto y está organizado de la siguiente forma:

- Advanced Analytics, son 4 data scientists (una economista, un actuario, una informática los tres con una maestría en ciencia de datos más una PhD en física) los que poseen entre 3 y 12 años de experiencia en ciencia de datos. Usted acaba de ingresar como la quinta persona, la más junior de ese equipo aún sin finalizar la maestría. Todo este sector reporta directamente a Michelina Porto, ya que advanced analytics es donde ella más interactúa.
- Data Engineering 7 personas, todos con sólida formación en sistemas (hay especialistas en Big Data, en cloud computing, en arquitectura de data lakes, en infraestructura y en MLOPs que se encargan de poner en producción los modelos desarrollados por los data scientists)
- Data Verticals 10 personas provenientes de las más diversas carreras, parte de ellos son data analysts
- CRM & Campaign Managing 3 personas
- Reporting, 6 personas que mantienen los reportes y además hacen análisis simples ad-hoc .
- Data Governance 1 *vigilante*

El sector ha existido en la organización por más de 20 años, evolucionando con diversas responsabilidades, nombres y estructuras. Decididamente usted **no** ha llegado como la salvación del sector que viene a reinventar la forma de trabajo y a reescribir todo de cero. El sector ya tiene una metodología de trabajo, decenas de repositorios de datos, cientos de scripts, ecosistema en el cual usted debe aprender a manejarse y agregar valor.

Todo el sector considera muy importante la reutilización de código. Todas las mejoras, previamente documentadas son bienvenidas. Reescribir de cero un script que ya está en el repositorio y es eficiente es visto como muy antieconómico en el sector.

La reproducibilidad de los experimentos es considerada de capital importancia en el sector. Es sagrado que quede la historia de los experimentos sub óptimos y se enseña a todos los integrantes a documentar y a aprender de lo que no funciona tan bien.

Luego de cuatro meses aprendiendo del ecosistema, le encargaron el proyecto del modelo predictivo de retención proactiva de clientes, lo ha terminado y ahora debe comunicar dos aspectos muy distintos de lo analizado a dos interlocutores.

Se deberán confeccionar dos videos, uno dirigido la gerenta de business intelligence y otro a la directora comercial. La duración de los videos debe estar en el entorno de los 5 minutos.

Michelina Porto, 38 años, es la gerenta de business intelligence de la compañía, es su jefa directa y fue quien hizo su contratación hace 4 meses.

Michelina posee un título de grado de Actuaria, desde su graduación se dedicó a análisis econométricos en

riesgo crediticio, en el año 2011 cursó una maestría en ciencia de datos e ingresó a trabajar a la compañía en el año 2017, ya en 2020 la ascendieron a gerenta en medio de una reorganización general de toda el área comercial. Michelina es una persona muy metódica y organizada, pausada en su hablar, elige sus palabras con gran precisión, reflexiva, considera muchas opciones antes de tomar una decisión, ante una situación difícil a resolver escribe un cuadro de excel con las alternativas a las que les estima una probabilidad. Michelina no transparenta fácilmente sus emociones. En las reuniones va escribiendo la minuta en tiempo real y la disponibiliza a todos ni bien termina. Es una persona muy focalizada y ninguna idea foránea la distrae del problema que debe resolver. Prefiere aprender en forma estructurada y abordar los temas desde lo abstracto.
La frase de cabecera de Michelina es : “no me cuentes que encontraste un patrón en los datos si no me traés como lo podemos utilizar para aumentar la rentabilidad”.

Michelina posee un elevado sentido de la ética y la justicia.

Al momento de comenzar el proyecto usted ya le hizo una primera presentación a Michelina, en donde le planteó el problema a resolver, la campaña de retención proactiva, la clase { BAJA+1, BAJA+2, CONTINUA } , que a los BAJA+1 se llega tarde y no se los puede retener, la fórmula de ganancia, la cantidad de datos disponible, el momento del mes en que los datos están disponibles, esto NO lo podrá volver a repetir en la segunda presentación.

Ha pasado el tiempo, usted ha concluido el modelo de attrition y Michelina espera de usted un segundo video con una breve presentación de alrededor de 5 minutos en donde con un storytelling le cuente la forma en que resolvió el problema, qué funcionó en forma sub óptima, que funciono mejor, los hallazgos más importantes y cómo eso se va a transformar en rentabilidad. Esta no es una tesis de maestría, usted no debe explicar el algoritmo árbol de decisión ni gradient boosting, usted debe ir al grano con Michelina, pero sorprenderla, y debe narrar lo que no funcionó.

Michelina reporta a la directora comercial y es la "gerenta de menos peso". Sus pares son las siguientes gerencias : sucursales (1000 comerciales), productos pasivos, productos activos, canales digitales, marketing, telemarketing y atención al cliente.

En las reuniones semanales que Michelina mantiene con su jefa contándole el avance de los múltiples proyectos de sector, ella le pide información adicional sobre el proyecto de retención proactiva de clientes y Michelina le solicita a usted hacer esa presentación en un video para que empiece a figurar en el radar de la compañía.

Miranda Wintour, argentina, 48 años, dos hijas gemelas pre adolescentes, es la directora comercial de la compañía desde hace dos años y medio, y en su meteórica carrera se pronostica que llegará a la gerencia general en dos años más.

Ambos padres de Miranda son nacidos fuera de Argentina dedicados en su momento a la actividad consular. Miranda de joven emigró, concluyó sus estudios secundarios en el UWC Atlantic College en Gales, se graduó con honores en Ciencias Políticas en la Sorbonne Université de París y cursó una maestría en economía en la London School of Economics and Political Science.

Miranda practica yachting desde su infancia, actividad fomentada por su padre quien le inculcó el trabajo en equipo y la competitividad. En su juventud participó de varias competencias internacionales, siendo un punto de inflexión en su vida la accidentada carrera de 1998 *54th Sydney to Hobart Yacht Race*. En su oficina posee un cuadro de muy importantes dimensiones con una fotografía de esa carrera en donde se aprecia a una joven Miranda formando parte de un numeroso equipo sobre una embarcación, al pie del cuadro reza una enorme leyenda “Las regatas se ganan en tierra”.

Miranda se unió desde muy joven a la compañía en Europa, estuvo a cargo del área Fintech europea y la convencieron de hacerse cargo en Argentina de una transformación radical. Su primera tarea fue

desarticular el anquilosado club de amigos que había formado su antecesor.

Aunque va con una sonrisa y su tono de voz es muy bajo y sereno, todos tienen una especie de temor hacia ella. Se dice cuando luego de una exposición Miranda le dice al disertante "buen trabajo" sonriendo, antes de los tres meses esa persona ya no está más en la compañía.

Usted jamás ha participado en una reunión con ella y esta será su gran oportunidad de darse a conocer, Miranda busca ideas revolucionarias que le permitan aumentar la posición de liderazgo que ya ostenta la compañía.

Un total de 2500 personas dependen indirectamente de Miranda, estando el grueso en la red de sucursales. telemarketing y atención al cliente.

Usted debe realizar un video presentación a Miranda que no puede exceder 5 minutos en donde le explique los perfiles de los clientes que se dan de baja de paquete premium y proponga acciones para revertirlo. Miranda no sabe (ni le interesa saber) sobre Ciencia de Datos pero está absolutamente convencida de las posibilidades que brinda la tecnología para tratar uno a uno a los clientes.

Debe quedarle muy claro que el video a Miranda no es contarle lo mismo que Michelina pero en palabras de negocios, Miranda le está pidiendo los perfiles de los clientes que dejan de tener Paquete Premium e ideas de como evitarlo, ideas basadas en evidencia que debe salir de los datos.
Debe quedarle claro que la tarea de un modelo predictivo es, situados dos meses antes, diferenciar a los que van a vivir de los que van a morir; Miranda le está pidiendo algo distinto : "en que se diferencian entre sí los que ya han muerto"

29.2 Bibliografía Introductoria Storytelling

- https://www.youtube.com/watch?v=3KQaWHesWwc
- https://jtappler.medium.com/effective-data-storytelling-and-visualization-81ad24229745 (5 minutos)
- https://www.youtube.com/watch?v=9UNlHFfy4hs (4 minutos)
- https://www.themuse.com/advice/public-speaking-tips (10 minutos)
- https://www.researchgate.net/publication/262393281_How_video_production_affects_student_engagement_An_empirical_study_of_MOOC_videos (15 minutos)

  https://www.youtube.com/watch?v=ba-CB6wVuvQ (15 minutos)

29.3 Herramientas para grabar videos

- Herramientas online, all included
  - https://prezi.com/
  - https://www.loom.com/

- Herramientas locales
  - grabación sencilla (ver siguiente capítulo)
  - https://obsproject.com/
  -

29.4 Grabación sencilla de videos con Microsoft Teams

Esta forma de grabar videos en Windows fue propuesta por un alumno y se hizo popular entre sus compañeros

1. descargar microsoft teams 1. https://www.microsoft.com/es-ww/microsoft-teams/download-app
2. abrir teams, e ir a "Meet Now" para crear una sala vacía con tu cámara.
3. abrir la meet estará usted solo y nadie más
4. dar click a "Share" y elegir tu tipo de pantalla: Standout, side-by-side o Reporter, y elegir Window para que muestre una pantalla y al lado su cámara
5. elegir tamaño de cámara (su imagen) y posición left-right de la cámara, recordar que debe ser al menos el 10% de la superficie (se puede elegir otro tipo de composición, que no recorte el fondo, dando un resultado más formal)
6. Presionar las teclas Windows + G, para abrir consola de grabación de Windows
7. Elegir bien la fuente (su pantalla compartida del Microsoft Teams) y darle a REC (el botón redondito que debería ser rojo pero ahí es blanco)
8. No olvidarse de activar el audio para que grabe con audio
9. también se puede grabar directamente usando el shortcut ALT+WIN+R y arranca a grabar directamente
10. Arrancar el speech pitch del video con la ppt
11. A finalizar, detener el video
12. Volver a abrir la consola de grabación con windows + G para encontrar el video guardado: poner open file location:
13. ingresar a youtube y subir el video
14. detalle: revisar que cuando se inicia la grabación con Windows G, el recording sea SOBRE el meeting, así graba el video que está sucediendo dentro de la ventana del meeting.

29.5 Torneo de Videos

Los videos se calificarán mediante la metodología *Swiss-system tournament* con el método de apareo *Dutch system* (ver https://en.wikipedia.org/wiki/Swiss-system_tournament) este método implica la existencia de rondas y que en cada ronda hay duelos de videos donde se intenta que compitan videos de similar calidad. Solo se pasa a la ronda siguiente una vez que todos los duelos hayan sido calificados.

Habrá un torneo para el video a Michelina Porto y otro torneo para el video a Miranda Wintour. Habrá una ronda diaria de cada uno de los dos torneos.

Los jueces de cada duelo serán los mismos alumnos y también los profesores. Se espera que cada alumno sea juez en al menos 6 duelos de cada torneo. Esto significa que cada alumno deberá ver $2*\log_2($ `cantidad_alumnos` $)$ videos dirigidos a Michelina Porto y la misma cantidad de Miranda Wintour. Nadie será juez de sus propios videos ni de compañeros. La votación en los duelos de videos es secreta.

La nota que se asigna por ser juez en el torneo de videos es simbólica ya que apenas representa el 2% de la nota final de la asignatura y está regida por el cumplimiendo en su rol como jurado. Se pretende que TODOS los alumnos participen en todas las rondas como jueces.

La frase del informe "En cuanto a limpieza de datos si bien hicimos tratamientos de nulos con rpart, no lo

convalidamos con la ganancia por lo que lo desestimamos. En una primera instancia nos dio resultados positivos pero repitiendo las pruebas esto no sucedió.“ no me queda clara ¿Podría explicar en gran detalle ?

30 Artículos de negocios

- https://storage.googleapis.com/open-courses/dmeyf/annotation/general/Target.html
- https://storage.googleapis.com/open-courses/dmeyf/annotation/general/why_business_fail_at_machine_learning.html
- https://storage.googleapis.com/open-courses/dmeyf/annotation/general/why_so_many_data_scientists_are_leaving_their_jobs.html
- https://storage.googleapis.com/open-courses/dmeyf/annotation/general/MostMisunderstoodHero.html

31 El Recuperatorio

El recuperatorio está destinado a personas que habiendo asistido al 75% de las clases, o no cumplieron con la entrega de todas las actividades obligatorias o

32 Hoja de Ruta clases jueves en construcción

Hoja de ruta de la Comisión 2, clases dictadas los jueves, por Gustavo Denicolay
Las clases de los lunes y jueves no están sincronizadas, ni siquiera se dictan los mismos temas, y por supuesto cada profesor tiene su formato y estilo propios.

Esta hoja de ruta es tentativa, se irá actualizando en función del conocimiento previo que tengan los alumnos lo que se indagará en la primera clase, el avance real que se logre en cada clase, la resistencia que se encuentre en los alumnos a abandonar conocimientos previos erróneos.

32.1 Introducción y construcción Primera Competencia

Clase 01, jueves 13-agosto, presencial

- presentación de la materia, la metodología de enseñanza, herramientas a utilizar, lenguajes y ambientes.
- Indagación sobre lo aprendido en materias del primer cuatrimestre, especialmente por la ausencia de Aprendizaje Automático este 2026
- Presentación del problema de negocios a resolver. Presentación de la Primera Competencia.
- Primera actividad de active learning sobre la fórmula de ganancia

Clase 02, jueves 20-agosto, presencial

- hiperparámetros del árbol librería rpart
- training/testing/ datos del futuro
- efecto de la semilla en training/testing, actividad de active learning
- Montecarlo Estimation, Cross Validation, Test de Wilcoxon
- Tarea para el hogar : Grid Search, experimentos encargados a los alumnos : corrida de 12+ horas de duración

Clase 03, jueves 27-agosto, presencial

- análisis de los resultados de las corrida de Grid Search, actividad de active learning, el infame hiperparámetro cp
- problemas de overfitting
- posibles optimizaciones al Grid Search, actividad de active learning
- Bayesian Optimization
- Tarea para el Hogar: corridas de Bayesian Optimization de árboles de decisión

Clase 04, jueves 03-septiembre, presencial

- Análisis corridas Bayesian Optimization de árboles de decisión
- Métodos de Ensemble
  - Arboles Azarosos
  - Random Forest
  - Gradient Boosting of Decision Trees
- Tarea para el Hogar: Bayesian Optimization de LightGBM

Clase 05, jueves 10-septiembre, presencial

- Análisis corrida Bayesian Optimization de LightGBM
- Profundizacion en hiperparámetros de LightGBM

Clase 06, jueves 17-septiembre, presencial

- Storytelling (Silvana Contreras)
- Distancia Random Forest, Clustering Jerárquico

Clase 07, jueves 24-septiembre, presencial

- Experimento: Clase Ternaria vs Clase Binaria. Curva de Ganancia
- Experimento: Feature Engineering Histórico, lags y delta-lags

domingo 27 septiembre, entrega video Miranda Wintour

Clase 08, jueves 01-octubre, presencial

- Experimento: Feature Engineering : creando variables para ser utilizadas por LightGBM a partir de Random Forest
- Data Drifting

domingo 04 octubre, cierre Primera Competencia

lunes 05 ocutbre, lanzamiento Última Competencia

Clase 09, jueves 08-octubre, presencial

- checkpoint de la materia, escuchar a los alumnos proponer cambios y mejoras
- exposición ganadores de la Primera Competencia

- análisis de los resultados de la Primera Competencia

32.2 Construcción Ultima Competencia

Clase 10, jueves 15-octubre, presencial

- Exposición de experimentos colaborativos, dinámica active learning
- Feature Engineering de variables históricas
    - Medias Móviles
    - Tendencias
    - ¿Ajuste por inflación?
    - Rankeo de Variables
    - Efecto de las variables históricas en Random Forest

Clase 11, jueves 22-octubre, presencial

- Exposición de experimentos colaborativos, dinámica active learning
- ¿En qué meses conviene entrenar?
- Undersampling de la clase mayoritaria para acelerar el procesamiento. ¿El undersampling mejora el poder predictivo del modelo?
- técnica de Walk Forward Validation
- experimentos encargados a alumnos : profundización en la Training Strategy

Clase 11, jueves 29-octubre, presencial

- Exposición de experimentos colaborativos, dinámica active learning
- ¿En qué meses conviene entrenar?
- Undersampling de la clase mayoritaria para acelerar el procesamiento. ¿El undersampling mejora el poder predictivo del modelo?
- técnica de Walk Forward Validation
- experimentos encargados a alumnos : profundización en la Training Strategy

Clase 13, jueves 05-noviembre, presencial, clase plenaria, ambas comisiones

- Tema Sorpresa

Clase 14, jueves 12-noviembre, presencial

- Ensemble stacking

- Valores Shapley
- Exposición de experimentos colaborativos, dinámica active learning

Clase 15, jueves 18 noviembre, presencial

- Exposición de experimentos colaborativos, dinámica active learning

Clase 16, jueves 26-noviembre, presencial

- Exposición de experimentos colaborativos, dinámica active learning

Clase 17, jueves 03-diciembre, presencial

- Exposición de experimentos colaborativos, dinámica active learning

Clase 18, jueves 10-diciembre, presencial

- examen individual escrito de puño y letra escrito / examen oral individual presencial

domingo 13-diciembre entrega de video Michelina Porto

lunes 14-diciembre Inicio Torneo de Videos

sábado 19-diciembre Fin Torneo de Videos

domingo 20-diciembre publicacion notas en cartelera Zulip